

Dictionnaire des variables

cm03-salaires.csv

Analyse des données — L3 Économie — CY Cergy Paris Université

Avertissement

Ces données sont fabriquées pour l'enseignement. Les ordres de grandeur, les codages et les conventions d'écriture reproduisent ceux d'un fichier de diffusion de la statistique publique française. Les valeurs, elles, ne sont celles d'aucune source réelle. Aucun chiffre de ce fichier ne doit être cité comme un fait.

Ce que le fichier reproduit fidèlement, en revanche, ce sont les difficultés : non-réponse codée en chiffres, hors champ distinct de la non-réponse, censure haute décidée par le producteur, unité statistique qui n'est pas celle qu'on croit.

Format du fichier

Encodage	latin-1
Séparateur de colonnes	point-virgule ;
Séparateur décimal	virgule
Séparateur de milliers	espace
Lignes	8 012 (dont 12 doublons techniques)
Colonnes	15

Chargement correct :

```
brut = pd.read_csv("cm03-salaires.csv", encoding="latin-1", sep=";",  
                  decimal=".", thousands=" ",  
                  dtype={"IDENT": str, "SECTEUR": str, "REGION": str})
```

Unité statistique

Une ligne est un poste occupé dans l'année, pas une personne. Une personne ayant occupé deux emplois apparaît deux fois, avec le même **IDENT** et deux valeurs de **NOPOSTE**.

La clé du fichier est donc le couple **IDENT** + **NOPOSTE**. Le fichier contient 7 380 personnes distinctes pour 8 000 postes, une fois les doublons techniques retirés.

Les variables

IDENT

Identifiant de la personne. Texte de 8 caractères, zéros initiaux compris. À charger en **str** : lu comme un entier, il perd ses zéros et ne s'apparie plus à aucun autre fichier.

Champ. Toutes les lignes. **Non-réponse.** Aucune.

NOPOSTE

Numéro du poste dans l'année pour cette personne. Numérique, 1 ou 2.

Champ. Toutes les lignes. **Non-réponse.** Aucune.

SEXE

Numérique. 1 = homme 2 = femme

Champ. Toutes les lignes. **Non-réponse.** Aucune.

AGE

Âge révolu en années. Numérique, de 15 à 74.

Champ. Toutes les lignes. **Non-réponse.** Aucune.

DIPLOME

Diplôme le plus élevé obtenu. Numérique.

- 1 Aucun diplôme
- 2 BEPC, brevet des collèges
- 3 CAP, BEP
- 4 Baccalauréat
- 5 Bac + 2
- 6 Bac + 3 ou + 4
- 7 Bac + 5 ou plus

Champ. Toutes les lignes. **Non-réponse.** codée **9**.

STATUT

Statut d'emploi. Numérique.

- 1 Salarié du secteur privé
- 2 Salarié du secteur public
- 3 Non-salarié (indépendant, employeur, aide familial)

Champ. Toutes les lignes. **Non-réponse.** Aucune.

CONTRAT

Type de contrat de travail. Numérique.

- 1 CDI
- 2 CDD
- 3 Intérim
- 8 Sans objet : non-salarié
- 9 Non-réponse

Champ. Toutes les lignes ; la modalité 8 marque le hors champ. **Non-réponse.** codée **9**.

TEMPS

Temps de travail déclaré. Numérique.

- 1 Temps complet
- 2 Temps partiel
- 9 Non-réponse

Champ. Toutes les lignes. **Non-réponse.** codée **9**.

HEURES

Nombre d'heures hebdomadaires habituellement travaillées dans ce poste. Numérique.

Censure haute. Les durées supérieures à 60 heures sont regroupées : la modalité 60 se lit « **60 heures ou plus** ». Toute moyenne calculée sur cette colonne est une borne inférieure de la durée réelle.

Champ. Toutes les lignes. **Non-réponse.** codée **99**.

MOTIF_ABS

Motif de l'absence au cours de la semaine de référence. Numérique.

- 1 Congés
- 2 Maladie
- 3 Congé de maternité ou de paternité
- 4 Formation
- 5 Raisons familiales
- 9 **Chômage partiel**
- 99 **Non-réponse**

Attention. Sur cette variable, 9 est une situation réelle et non une non-réponse. La non-réponse est codée 99. Un `replace(9, NaN)` appliqué par habitude supprime une catégorie entière.

Champ. Personnes absentes de leur poste au cours de la semaine de référence. La case est **vide** pour les autres : c'est du **sans objet**, pas de la non-réponse. **Non-réponse.** codée **99**.

SALAIRE_NET

Salaire mensuel net en euros, virgule décimale, espace pour les milliers.

Censure haute. Les salaires supérieurs à 10 000 euros sont ramenés à 10 000 : c'est le plafond de diffusion. Tout indicateur d'inégalité calculé sur cette colonne est une borne inférieure.

Champ. Salariés uniquement. La valeur est **0** pour les non-salariés : c'est du **sans objet**. Un non-salarié ne perçoit pas de salaire, il n'a pas un salaire nul. **Non-réponse.** codée **999 999**.

PRIME

Montant annuel des primes perçues, en euros.

Attention. La case **vide** signifie « **aucune prime perçue** », et non « non renseigné ». La distinction change la moyenne d'un facteur deux selon qu'on la traite comme un zéro ou comme un manquant. Dites laquelle des deux vous avez retenue.

Champ. Salariés uniquement. **Non-réponse.** codée **999 999**.

ANCIENNETE

Ancienneté dans l'entreprise, en années révolues. Numérique.

Champ. Salariés uniquement. La valeur est **-1** pour les non-salariés : **sans objet**. **Non-réponse.** Aucune.

SECTEUR

Secteur d'activité, en nomenclature agrégée. Texte de deux caractères.

AZ Agriculture, sylviculture, pêche
 BE Industrie manufacturière, extractive
 FZ Construction
 GZ Commerce, réparation d'automobiles
 HZ Transports et entreposage
 JZ Information et communication
 MN Activités scientifiques, techniques, services administratifs
 OQ Administration publique, enseignement, santé, action sociale
 RU Autres activités de services

Champ. Toutes les lignes. **Non-réponse.** Aucune.

REGION

Code de la région de l'établissement. Texte de deux caractères, zéro initial compris. À charger en `str`.

Champ. Toutes les lignes. **Non-réponse.** Aucune.

Récapitulatif des codes à connaître

Variable	Non-réponse	Sans objet	Censure
DIPLOME	9	—	—
CONTRAT	9	8	—
TEMPS	9	—	—
HEURES	99	—	60 heures ou plus
MOTIF_ABS	99	case vide	—
SALAIRE_NET	999 999	0	10 000 euros
PRIME	999 999	case vide	—
ANCIENNETE	—	−1	—

Trois colonnes utilisent le code 9, et il ne veut pas dire la même chose dans les trois. Lisez la ligne de la variable, pas la colonne du code.

`stefaniarmacassa.github.io/analyse_des_donnees`