

Présentation du cours

Analyse des données — Séance 0

Stefania Marcassa

CY Cergy Paris Université — L3 Économie

Ce que nous allons faire

Ce que vous saurez faire en décembre

1. **Trouver et charger** des données économiques réelles, et lire la documentation d'une source.
2. **Nettoyer et restructurer** un jeu de données brut.
3. **Produire des statistiques descriptives défendables.**
4. **Construire des graphiques honnêtes.**
5. **Estimer et lire une régression** en pratique.
6. **Rendre un travail reproductible.**

Le critère

Qu'une autre personne puisse ré-exécuter votre code et retrouver vos résultats.

Ce cours et celui d'économétrie

Vous suivez les deux ce semestre. Ils ne traitent pas du même problème.

	Économétrie	Analyse des données
Part de	un jeu de données propre	un fichier brut, mal formé
La question	quel estimateur, sous quelles hypothèses ?	quelles données, et que mesurent-elles ?
La difficulté	les propriétés de l'estimateur	les décisions sur les données
Le produit	un coefficient et son écart-type	un fichier utilisable et un journal de décisions

Les deux se rejoignent aux séances 7 et 8, quand nous estimerons de vraies régressions sur des données que vous aurez vous-mêmes construites.

Ce que ce cours n'est pas

Ce n'est pas un cours d'économétrie théorique. Il n'y aura aucune démonstration.

C'est un cours de **mise en œuvre** : la difficulté est dans les données, pas dans les formules.

On estime couramment qu'un économiste consacre environ **un tiers** de son temps de recherche empirique à obtenir et nettoyer ses données. Ce tiers-là n'est enseigné nulle part ailleurs dans votre cursus.

Une mise en garde, dès aujourd'hui

Une régression ne mesure pas un effet causal. Elle mesure une association conditionnelle aux variables incluses.

Tout le métier tient dans l'écart entre les deux. Nous y reviendrons à partir de la séance 7.

Les dix séances

Séance		Application en TD
1	Environnement et anatomie des données	Indice des prix harmonisé
2	Chargement, inspection, filtrage	Recensement, taux de chômage
3	Nettoyage des données	Salaires
4	Restructuration et fusion	Émissions et revenus des communes
5	Décrire, comparer, conclure	Distribution des revenus
6	Visualisation	Courbe de Beveridge
7	Régression en pratique I	Équation de Mincer
8	Régression en pratique II	Prix de l'immobilier
9	Séries temporelles et API	Rendements boursiers
10	Prédiction et synthèse	Sujet d'annale

Chaque séance de TD porte sur des données économiques réelles, issues de sources publiques que vous retrouverez en stage puis en M1.

- **INSEE** — recensement, FiLoSoFi, DADS
- **DARES** — offres et demandes d'emploi
- **DVF** — transactions immobilières
- **Eurostat, ADEME** — indices de prix, émissions communales
- Données de marché — cours et indices boursiers

Aucun jeu de données d'exercice. Aucun fichier propre au départ.

Où ce cours se situe dans votre parcours

Avant	Statistiques descriptives, Probabilités, Analyse statistique
Ce semestre	Économétrie + Analyse des données
Semestre 6	Statistiques et informatique, Méthodologie des enquêtes Stage obligatoire, huit semaines minimum
Ensuite	Master Économie, Data et Transition · Finance · Management

La raison la plus concrète

Dans quatre mois, vous serez en stage. On vous confiera un fichier mal formé et une question. Ce que nous faisons ce semestre est exactement cela.

Comment cela se passe

En cours

Les concepts, les commandes, et surtout les décisions à prendre.

En TD

25 min de retour sur l'exercice

30 min de résolution en direct

45 min de travail autonome

Trois fichiers par séance, sur le site du cours :

- le **notebook à trous** — à ouvrir *avant* le TD ;
- le **script complet** — mis en ligne après ;
- l'**exercice** — à traiter pour la fois suivante.

Épreuve	Poids	Durée	Périmètre
Contrôle continu	50 %	1 h	Séances 1 à 5
Contrôle terminal	50 %	2 h	Ensemble du cours

Les deux épreuves se déroulent **sur papier, sans machine**.

Aucune ne demande d'écrire du code de mémoire.

Les exercices hebdomadaires ne sont pas notés — mais les questions de diagnostic des épreuves sont construites à partir des erreurs qui y reviennent.

Quatre types de questions

1. **Lecture de sortie.** Un tableau ou une régression vous est donné : que montre-t-il, et que ne montre-t-il pas ?
2. **Diagnostic.** Un extrait de données ou de code contient un problème : l'identifier, proposer une correction.
3. **Interprétation économique.** Que peut-on affirmer à partir de ce coefficient, et sous quelles conditions ?
4. **Code court.** Trois à cinq lignes à écrire ou compléter — jamais un script entier.

Ce qui est évalué n'est pas la syntaxe. C'est le **jugement sur les données**.

Autorisés et attendus pour les exercices. C'est l'outil de travail réel de votre future profession.
Interdits lors des deux épreuves, qui se tiennent sans machine.

Ce qu'ils font bien, ce qu'ils font mal

Un assistant écrit très bien la syntaxe.

Il est peu fiable sur les décisions qui font l'objet de ce cours : quelle variable retenir, comment traiter les manquants, quelle spécification est défendable, ce qu'un coefficient autorise à conclure.

Si vous ne pouvez pas expliquer une ligne qu'il a produite, vous ne saurez pas répondre à la question de diagnostic qui portera dessus.

Pour commencer

Avant la séance 1

1. Créez un compte Google si vous n'en avez pas.
2. Ouvrez `colab.research.google.com` et vérifiez que la page se charge.
3. Aucune installation n'est nécessaire. Ne téléchargez rien.

Tout le matériel du cours — calendrier, notebooks, diapositives, syllabus — se trouve sur :

`stefaniamarcassa.github.io/analyse_des_donnees`

Des questions ?