

# Présentation du cours

Analyse des données — Séance 0

---

Stefania Marcassa

CY Cergy Paris Université — L3 Économie

**Ce que nous allons faire**

---

# Ce que vous saurez faire en décembre

1. **Trouver et charger** des données économiques réelles, et lire la documentation d'une source.
2. **Nettoyer et restructurer** un jeu de données brut.
3. **Produire des statistiques descriptives défendables.**
4. **Construire des graphiques honnêtes.**
5. **Estimer et lire une régression** en pratique.
6. **Rendre un travail reproductible.**

## Le critère

Qu'une autre personne puisse ré-exécuter votre code et retrouver vos résultats.

# Ce que ce cours n'est pas

Ce n'est pas un cours d'économétrie théorique. Les propriétés des estimateurs sont supposées connues.

C'est un cours de **mise en œuvre** : la difficulté est dans les données, pas dans les formules.

## **Une mise en garde, dès aujourd'hui**

Une régression ne mesure pas un effet causal. Elle mesure une association conditionnelle aux variables incluses.

Tout le métier tient dans l'écart entre les deux. Nous y reviendrons à partir de la séance 7.

# Les dix séances

| Séance |                                       | Application en TD        |
|--------|---------------------------------------|--------------------------|
| 1      | Environnement et anatomie des données | Indice des prix          |
| 2      | Chargement, inspection, filtrage      | Enquête Emploi           |
| 3      | Nettoyage des données                 | Salaires                 |
| 4      | Restructuration et fusion             | Panel Eurostat           |
| 5      | Statistiques descriptives             | Distribution des revenus |
| 6      | Visualisation                         | Courbe de Beveridge      |
| 7      | Régression en pratique I              | Équation de Mincer       |
| 8      | Régression en pratique II             | Prix de l'immobilier     |
| 9      | Séries temporelles et API             | Rendements boursiers     |
| 10     | Prédiction et synthèse                | Sujet d'annale           |

Chaque séance de TD porte sur des données économiques réelles, issues de sources publiques que vous retrouverez en M1.

- **INSEE** — Enquête Emploi, FiLoSoFi, DADS
- **DARES** — offres et demandes d'emploi
- **DVF** — transactions immobilières
- **Eurostat, FRED** — comptes nationaux, séries macroéconomiques
- Données de marché — cours et indices boursiers

Aucun jeu de données d'exercice. Aucun fichier propre au départ.

Comment cela se passe

---

## En cours

Les concepts, les commandes, et surtout les décisions à prendre.

## En TD

25 min de retour sur l'exercice  
30 min de résolution en direct  
45 min de travail autonome

Trois fichiers par séance, sur le site du cours :

- le **notebook à trous** — à ouvrir *avant* le TD ;
- le **script complet** — mis en ligne après ;
- l'**exercice** — à traiter pour la fois suivante.



| Épreuve           | Poids | Durée | Périmètre         |
|-------------------|-------|-------|-------------------|
| Contrôle continu  | 40 %  | 1 h   | Séances 1 à 5     |
| Contrôle terminal | 60 %  | 2 h   | Ensemble du cours |

Les deux épreuves se déroulent **sur papier, sans machine**.

Aucune ne demande d'écrire du code de mémoire.

Les exercices hebdomadaires ne sont pas notés — mais les questions de diagnostic des épreuves sont construites à partir des erreurs qui y reviennent.

# Quatre types de questions

1. **Lecture de sortie.** Un tableau ou une régression vous est donné : que montre-t-il, et que ne montre-t-il pas ?
2. **Diagnostic.** Un extrait de données ou de code contient un problème : l'identifier, proposer une correction.
3. **Interprétation économique.** Que peut-on affirmer à partir de ce coefficient, et sous quelles conditions ?
4. **Code court.** Trois à cinq lignes à écrire ou compléter — jamais un script entier.

Ce qui est évalué n'est pas la syntaxe. C'est le **jugement sur les données**.

Autorisés et attendus pour les exercices. C'est l'outil de travail réel de votre future profession.  
Interdits lors des deux épreuves, qui se tiennent sans machine.

## **Ce qu'ils font bien, ce qu'ils font mal**

Un assistant écrit très bien la syntaxe.

Il est peu fiable sur les décisions qui font l'objet de ce cours : quelle variable retenir, comment traiter les manquants, quelle spécification est défendable, ce qu'un coefficient autorise à conclure.

Si vous ne pouvez pas expliquer une ligne qu'il a produite, vous ne saurez pas répondre à la question de diagnostic qui portera dessus.

Pour commencer

---

# Avant la séance 1

1. Créez un compte Google si vous n'en avez pas.
2. Ouvrez `colab.research.google.com` et vérifiez que la page se charge.
3. Aucune installation n'est nécessaire. Ne téléchargez rien.

Tout le matériel du cours — calendrier, notebooks, diapositives, syllabus — se trouve sur :

`stefaniamarcassa.github.io/analyse_des_donnees`

Des questions ?