

Décrire, comparer, conclure

Analyse des données — Séance 5

Stefania Marcassa

CY Cergy Paris Université — L3 Économie

Où nous allons aujourd'hui

1. Décrire une distribution sans se faire piéger par elle.
2. Décrire par groupe : `groupby`, et l'effectif qu'on oublie.
3. Pondérer, parce qu'une enquête n'est pas un recensement.
4. Construire le tableau que contient tout article empirique.
5. Comparer deux groupes, et dire ce que la comparaison autorise à conclure.

Le fil de la séance

Un chiffre sans son effectif, sa dispersion et son incertitude n'est pas un résultat.

Décrire une distribution

Trois nombres, trois questions différentes

```
df["revenu"].describe()
```

- La **moyenne** répond à : quel est le total, réparti également ?
- La **médiane** répond à : où se situe la personne du milieu ?
- Les **quantiles** répondent à : quelle est la forme de la distribution ?

Sur les revenus, moyenne et médiane s'écartent systématiquement. Ce n'est pas un défaut des données : c'est l'asymétrie de la distribution, et c'est un fait économique.


Rapporter une moyenne sans la médiane sur une variable asymétrique est une faute.

Trois sortes de points problématiques

Valeur extrême

Loin des autres, mais dans la logique de l'ensemble.


Un très haut revenu dans une enquête sur les revenus.



Point atypique

N'appartient probablement pas à la population étudiée.


Une entreprise du CAC 40 dans un échantillon de PME.



Point influent




À lui seul, il change le résultat.

Se détecte en refaisant le calcul sans lui.



La question n'est jamais « faut-il le supprimer ? » mais « d'où vient-il ? ».

Les repérer : trois regards — 1/5



Histogramme

La forme d'ensemble :
asymétrie, et un pic isolé à 10
000 €.

Boîte à moustaches

Les points au-delà des
moustaches — ici, une masse
entière.

Nuage de points

Ils se répartissent sur tous les
âges : ce n'est pas un
sous-groupe.

La règle des 1,5 écarts interquartiles — 2/5

```
q1, q3 = df["SALAIRE_NET"].quantile  
        ([.25, .75])  
iqr     = q3 - q1  
seuil   = q3 + 1.5 * iqr
```

```
print(round(q1), round(q3), round(iqr))  
print(round(seuil))  
print((df["SALAIRE_NET"] > seuil).sum()  
      )
```

Sortie

```
1654 3155 1501  
5406  
269
```

La moitié centrale des salaires s'étend de 1 654 à 3 155 euros. Le seuil tombe à **5 406**, et la règle signale **269 salaires** — 3,9 % du fichier.

La question

Sont-ce 269 erreurs ?

Qui sont ces 269 points ? — 3/5

```
df.loc[df["SALAIRE_NET"] > seuil, "SALAIRE_NET"].describe()
```

count	269	min	5407
mean	7555	max	10000

Non. Le plus faible gagne 5 407 euros : aucun n'est aberrant. Ce sont des cadres et des dirigeants — la **queue de distribution**, que les revenus ont toujours longue à droite.

Et **72** d'entre eux valent exactement 10 000 : le plafond de diffusion. La règle signale donc des valeurs dont on ignore la vraie grandeur.

Le coefficient 1,5 ne repose sur aucune théorie : c'est le choix de celui qui a dessiné la boîte à moustaches. Sur une distribution asymétrique, il signale mécaniquement des observations valides.

D'où vient le point ? — 4/5

La question n'est jamais « faut-il le supprimer ? » mais « d'où vient-il ? ».

Origine	Comment le savoir	Traitement
Erreur de saisie	Valeur impossible : âge 300, salaire négatif	Corriger si possible, sinon mettre en manquant
Individu hors champ	Ne relève pas de la population étudiée	Écarter, et le dire
Valeur réelle	Rien ne la distingue, sinon sa taille	Conserver

Nos 269 salaires relèvent du troisième cas. **Les supprimer reviendrait à retirer les hauts revenus d'une étude sur les revenus.**

Ce que chaque choix coûte — 5/5

```
s = df["SALAIRE_NET"]  
p95 = s.quantile(.95)
```

```
s.mean(), s[s <= seuil].mean(), s.clip(upper=p95).mean()  
s.median(), s[s <= seuil].median()
```

	Moyenne		Médiane	
Tout conservé		2 610		2 322
Sans les 269 points	2 406	−7,8 %	2 276	−2,0 %
Plafonné au 95 ^e centile		2 510		2 322

La moyenne bouge de 8 %, la médiane de 2 % : la médiane est **robuste**, la moyenne ne l'est pas. C'est la raison pour laquelle on rapporte les deux.

En cas de doute : présentez le résultat **avec et sans**. C'est plus honnête qu'un arbitrage caché.

Décrire par groupe

Du niveau individuel au niveau groupe

```
df.groupby("SECTEUR")["SALAIRE_NET"].mean()
```

Trois opérations en une : **découper** selon une clé, **appliquer** un calcul à chaque morceau, **recoller** les résultats.

```
df.groupby("SECTEUR").agg(  
    salaire_moyen = ("SALAIRE_NET", "mean"),  
    salaire_median = ("SALAIRE_NET", "median"),  
    effectif      = ("SALAIRE_NET", "count")  
) .reset_index()
```

L'unité statistique a changé. Une ligne ne décrit plus un poste mais un secteur. Tout ce qui suit doit en tenir compte.

Le piège de l'effectif

```
r = df.groupby("AGE")["SALAIRE_NET"].agg(["mean", "count"])
r.sort_values("mean", ascending=False).head(3)
```

AGE	Salaire moyen	Effectif
68	4 167	7
52	3 173	159
60	3 159	101

Les 68 ans arrivent en tête — avec **sept** observations. Une moyenne calculée sur sept personnes est extrêmement variable : le classement mesure surtout la taille des groupes.

La règle

Un tableau agrégé s'accompagne **toujours** de l'effectif de chaque groupe. Sans lui, le lecteur ne sait pas ce qu'il regarde — et vous non plus.

Pondérer

Pourquoi une enquête est pondérée

Une enquête n'interroge pas tout le monde, et n'interroge pas chacun avec la même probabilité. Certaines catégories sont volontairement sur-représentées pour que l'échantillon reste exploitable.

Le poids d'un individu indique **combien de personnes il représente** dans la population.

Conséquence

Une moyenne calculée sans les poids décrit l'échantillon, pas la population. Elle est fausse pour toute question économique.

Pondérer en pratique

```
import numpy as np

# Faux : décrit l'échantillon
df["revenu"].mean()

# Juste : décrit la population
np.average(df["revenu"], weights=df["poids"])
```

Pour les proportions, le principe est le même : summez les poids de chaque modalité plutôt que de compter les lignes.

```
df.groupby("statut")["poids"].sum() / df["poids"].sum()
```

Une conséquence désagréable

La pondération complique aussi l'inférence : les erreurs-types calculées comme si l'échantillon était aléatoire simple sont sous-estimées, parfois nettement.

Un traitement rigoureux exige de connaître le plan de sondage — strates, grappes, degrés.

Ce que nous ferons

Nous pondérons les moyennes et les proportions, et nous signalons que les erreurs-types sont approximatives. C'est la pratique courante en travail appliqué, et elle doit être *dite*, non dissimulée.

Le tableau de comparaison

Le tableau que contient tout article empirique

	Groupe A	Groupe B	Écart
Revenu mensuel	2 140 (980)	1 880 (860)	260 [95 ; 425]
Âge	41,2 (11,4)	39,8 (12,1)	1,4 [−0,3 ; 3,1]
Observations	1 842	1 516	

Entre parenthèses : l'**écart-type**, qui décrit la dispersion des individus.

Entre crochets : l'**intervalle de confiance** de l'écart, qui décrit l'incertitude sur la moyenne.

Ce ne sont pas les mêmes objets, et les confondre est l'erreur la plus fréquente.

Écart-type et erreur-type

```
ecart_type = df["revenu"].std()
n           = df["revenu"].count()
erreur_type = ecart_type / np.sqrt(n)
```

- L'**écart-type** ne diminue pas quand l'échantillon grandit. Il décrit les individus.
- L'**erreur-type** diminue en $1/\sqrt{n}$. Elle décrit la précision de l'estimation.

Avec 40 000 observations, l'erreur-type devient minuscule alors que la dispersion des revenus reste énorme. Les deux informations sont vraies et disent des choses différentes.

Construire le tableau

```
df.groupby("groupe")["revenu"].agg(["mean", "std", "count"])
```

```
# Intervalle de confiance a 95 % d'une moyenne  
moyenne + np.array([-1.96, 1.96]) * erreur_type
```

Le 1,96 vaut pour un échantillon suffisamment grand. En dessous d'une trentaine d'observations par groupe, il faut la loi de Student — mais vos échantillons d'enquête n'auront jamais ce problème.

Ce qu'un intervalle de confiance dit, et ne dit pas

La formulation correcte

Si l'on répétait l'enquête un grand nombre de fois, 95 % des intervalles ainsi construits contiendraient la vraie valeur.

La formulation fausse, et très répandue

« Il y a 95 % de chances que la vraie valeur soit dans cet intervalle. »

La vraie valeur n'est pas aléatoire : elle est fixe et inconnue. C'est l'intervalle qui varie d'un échantillon à l'autre.

La distinction paraît scolastique. Elle est la raison pour laquelle un intervalle ne permet pas de dire ce qui est « probablement vrai ».

Une fonction, pas trois copier-coller

Vous produirez ce tableau pour plusieurs variables. Écrivez-le une fois.

```
def resume(data, variable, groupe, poids=None):  
    g = data.groupby(groupe)[variable]  
    out = g.agg(["mean", "std", "count"])  
    out["err_type"] = out["std"] / np.sqrt(out["count"])  
    out["ic_bas"] = out["mean"] - 1.96 * out["err_type"]  
    out["ic_haut"] = out["mean"] + 1.96 * out["err_type"]  
    return out.round(2)  
  
resume(df, "revenu", "groupe")
```

C'est la fonction écrite en séance 3, appliquée à un autre problème. Vous la réutiliserez au TD 5, puis pour votre mémoire.

Comparer deux groupes

La différence de moyennes

```
from scipy import stats

a = df.loc[df["groupe"] == "A", "revenu"]
b = df.loc[df["groupe"] == "B", "revenu"]

stats.ttest_ind(a, b, equal_var=False)
```

Écrivez toujours `equal_var=False`. C'est le test de Welch, qui ne suppose pas les variances égales.

On enseigne parfois de tester d'abord l'égalité des variances pour choisir le test. Cette pratique est déconseillée : le pré-test déforme le niveau du test final. Welch fonctionne dans les deux cas.

Ce qu'une p-value dit, et ne dit pas

Ce qu'elle est

La probabilité d'observer un écart au moins aussi grand que celui-ci, *si* les deux populations avaient la même moyenne.

- Ce n'est pas la probabilité que l'hypothèse nulle soit vraie.
- Ce n'est pas la probabilité que le résultat soit dû au hasard.
- Une p-value de 0,04 et une de 0,06 ne décrivent pas deux mondes différents.

Rapportez l'écart estimé et son intervalle de confiance. La p-value seule ne renseigne sur rien d'économique.

Significatif ne veut pas dire important

Avec 40 000 observations par groupe, un écart de salaire de 25 euros par mois — 1 % du salaire moyen — est statistiquement significatif.

Il n'a aucune signification économique.

Question	Réponse fournie par
L'écart est-il distinguable de zéro ?	la p-value
De quelle taille est-il ?	l'estimation ponctuelle
Avec quelle précision le connaît-on ?	l'intervalle de confiance
Est-il important ?	l'économie, pas la statistique

La dernière ligne est celle qu'on attend de vous.

Deux variables qualitatives

```
tableau = pd.crosstab(df["diplome"], df["statut"])  
stats.chi2_contingency(tableau)
```

Le test du khi-deux répond à une seule question : les deux variables sont-elles indépendantes dans la population ?

Dans cet ordre

Le tableau croisé se regarde *après* le test, pas avant. Conclure à l'indépendance parce que deux pourcentages se ressemblent, puis chercher un test qui confirme, inverse la démarche — et l'œil n'est pas un instrument de mesure.

Une limite du khi-deux

Le test dit si les variables sont liées. Il ne dit ni dans quel sens, ni avec quelle force, ni pourquoi.

Sur un grand échantillon, il rejette presque toujours l'indépendance — pour la même raison qu'un écart de 25 euros devient significatif.

Ce qui est plus informatif

Les proportions conditionnelles, ligne par ligne : quelle part de chaque niveau de diplôme se trouve au chômage. Le tableau parle davantage que le test.

Nous verrons en séance 7 comment traiter la même question en gardant une mesure d'ampleur.

Pour la suite

- Déciles, rapport interdécile, indice de Gini
- Le tableau de comparaison entre deux groupes, avec intervalles de confiance
- L'ensemble refait sans pondération, pour mesurer le biais

L'écart entre les versions pondérée et non pondérée sera plus grand que ce que la plupart d'entre vous anticipent. C'est le résultat à retenir de la séance.

Contrôle continu

Une heure, sur papier, sans machine. Date et périmètre précis annoncés sur le site du cours.

- Lecture de sortie — un tableau de comparaison vous est donné
- Diagnostic — un extrait de code ou de données contient un problème
- Interprétation — que permet de conclure cet écart, et sous quelles conditions
- Code court — trois à cinq lignes

Deux questions au moins porteront sur une **décision à justifier**. Il n'y a pas de bonne réponse unique ; c'est la justification qui est notée.

`stefaniamarcassa.github.io/analyse_des_donnees`

Des questions ?