

Décrire, comparer, conclure

Analyse des données — Séance 5

Stefania Marcassa

CY Cergy Paris Université — L3 Économie

Où nous allons aujourd'hui

1. Décrire une distribution sans se faire piéger par elle.
2. Décrire par groupe : `groupby`, et l'effectif qu'on oublie.
3. Pondérer, parce qu'une enquête n'est pas un recensement.
4. Construire le tableau que contient tout article empirique.
5. Comparer deux groupes, et dire ce que la comparaison autorise à conclure.

Le fil de la séance

Un chiffre sans son effectif, sa dispersion et son incertitude n'est pas un résultat.

Décrire une distribution

Trois nombres, trois questions différentes

```
df["revenu"].describe()
```

- La **moyenne** répond à : quel est le total, réparti également ?
- La **médiane** répond à : où se situe la personne du milieu ?
- Les **quantiles** répondent à : quelle est la forme de la distribution ?

Sur les revenus, moyenne et médiane s'écartent systématiquement. Ce n'est pas un défaut des données : c'est l'asymétrie de la distribution, et c'est un fait économique.

Rapporter une moyenne sans la médiane sur une variable asymétrique est une faute.

Les points problématiques

Toutes les observations ne se valent pas. Certaines enrichissent l'analyse, d'autres la faussent.


Les points problématiques sont ceux qui se tiennent anormalement loin des autres — souvent des maximums ou des minimums extrêmes. Avant toute analyse, il faut les examiner.

Trois types, à ne pas confondre

1. Les **valeurs extrêmes**
2. Les **points atypiques**
3. Les **points influents**

Ils ne se repèrent pas de la même façon, et ne se traitent pas de la même façon.

Les distinguer : deux critères



Valeur extrême

L'observation est loin des autres, mais reste dans la logique d'ensemble. Elle *n'appartient peut-être pas* à la population étudiée.

Point atypique

Sa position en X est ordinaire, mais son Y s'écarte. Une **variable explicative manque** au modèle.

Point influent

Loin en X et hors tendance. Il **baise le résultat** : la pente passe ici de 42 à 7.

Pourquoi ce point est-il là ? — 1/2

Comprendre l'origine d'un point problématique est ce qui détermine son traitement.

Une erreur manifeste → la corriger

Une note de 150 sur 20. La valeur est impossible : on la corrige, ou on la met en manquant.

Une variable omise → l'ajouter au modèle

Un logement bien plus cher que les autres de même surface. L'écart vient peut-être de l'emplacement — une variable qu'on n'avait pas retenue.

Un individu hors population → le retirer

Une Ferrari dans une étude sur l'effet de la puissance du moteur sur le prix, si l'on ne s'intéresse pas aux voitures de luxe.

Pourquoi ce point est-il là ? — 2/2

Il appartient bien à la population, mais reste très différent

On le **garde** et on le **surveille**. Le supprimer reviendrait à décrire une population dont on aurait retiré ce qui dérange.

Dans tous les autres cas, essayez plusieurs modèles et **présentez chaque résultat** :

- avec le point problématique ;
- sans lui ;
- avec lui, mais après correction.

C'est plus honnête qu'un arbitrage caché — et c'est ce qu'un lecteur attentif vous demandera de toute façon.

La statistique descriptive offre deux familles d'outils.

Les graphiques

Histogramme, boîte à moustaches, nuage de points.



Les statistiques de résumé

Premier quartile q_1 , troisième quartile q_3 , et leur écart — l'écart interquartile.

L'ordre compte. On commence par les **graphiques**, pour se faire une idée d'ensemble et repérer d'éventuels points problématiques. On applique *ensuite* une règle chiffrée — celle de l'écart interquartile — pour fixer un seuil.

Nous travaillons sur la variable SALAIRE_NET du fichier de salaires, **après les traitements du TD 3** : montants convertis en nombres, code 999 999 mis en manquant, salaires nuls écartés. Sans cela, les chiffres qui suivent seraient tout autres.

Détecter : les trois graphiques — 2/3



Histogramme

La forme d'ensemble : asymétrie à droite, et un **pic isolé à 10 000 €** — le plafond de diffusion.

Boîte à moustaches

Tout ce qui dépasse la moustache est signalé — ici, une masse entière.

Nuage de points

Les points signalés se répartissent sur tous les âges : ce n'est pas un sous-groupe.

Détecter : la règle de l'écart interquartile — 3/3

	Sortie
<code>q1, q3 = df["SALAIRE_NET"].quantile ([.25, .75])</code>	1654 3155 1501
<code>iqr = q3 - q1</code>	5406
<code>seuil = q3 + 1.5 * iqr</code>	269
<code>print(round(q1), round(q3), round(iqr))</code>	
<code>print(round(seuil))</code>	
<code>print((df["SALAIRE_NET"] > seuil).sum())</code>	

La moitié des salariés gagnent entre 1 654 et 3 155 euros. Le seuil tombe à **5 406** : la règle signale **269 salaires** sur 6 812, soit 3,9 %.

Sur un fichier non nettoyé

La même règle signalerait **717** observations, dont **525 codes 999 999**. Les non-réponses gonflent le seuil, puis se font signaler elles-mêmes.

Retirer ? Le test du « avec et sans »

```
df.loc[df["SALAIRE_NET"] > seuil, "SALAIRE_NET"].describe()
count    269      mean    7555      min    5407      max    10000

# moyenne avec, puis sans, les 269
2610      2406
```

Le coefficient 1,5 ne repose sur aucune théorie : c'est le choix de celui qui a dessiné la boîte à moustaches.

Le plus faible des 269 gagne 5 407 euros : un salaire de cadre, pas une anomalie. Ils appartiennent à la population — **premier cas de la diapositive précédente**.

Les retirer ferait baisser la moyenne de 204 euros, soit 8 %, et sous-estimerait l'inégalité qu'on prétend mesurer.

La règle de conduite

La règle de l'écart interquartile sert à **regarder**, jamais à supprimer automatiquement.

Décrire par groupe

Du niveau individuel au niveau groupe

```
df.groupby("SECTEUR")["SALAIRE_NET"].mean()
```

Trois opérations en une : **découper** selon une clé, **appliquer** un calcul à chaque morceau, **recoller** les résultats.

```
df.groupby("SECTEUR").agg(  
    salaire_moyen = ("SALAIRE_NET", "mean"),  
    salaire_median = ("SALAIRE_NET", "median"),  
    effectif      = ("SALAIRE_NET", "count")  
) .reset_index()
```

L'unité statistique a changé. Une ligne ne décrit plus un poste mais un secteur. Tout ce qui suit doit en tenir compte.

Le piège de l'effectif

```
r = df.groupby("AGE")["SALAIRE_NET"].agg(["mean", "count"])
r.sort_values("mean", ascending=False).head(3)
```

AGE	Salaire moyen	Effectif
68	4 167	7
52	3 173	159
60	3 159	101

Les 68 ans arrivent en tête — avec **sept** observations. Une moyenne calculée sur sept personnes est extrêmement variable : le classement mesure surtout la taille des groupes.

La règle

Un tableau agrégé s'accompagne **toujours** de l'effectif de chaque groupe. Sans lui, le lecteur ne sait pas ce qu'il regarde — et vous non plus.

Pondérer

Pourquoi une enquête est pondérée

Une enquête n'interroge pas tout le monde, et n'interroge pas chacun avec la même probabilité. Certaines catégories sont volontairement sur-représentées pour que l'échantillon reste exploitable.

Le poids d'un individu indique **combien de personnes il représente** dans la population.

Conséquence

Une moyenne calculée sans les poids décrit l'échantillon, pas la population. Elle est fausse pour toute question économique.

```
import numpy as np

# Faux : décrit l'échantillon
df["revenu"].mean()

# Juste : décrit la population
np.average(df["revenu"], weights=df["poids"])
```

Pour les proportions, le principe est le même : summez les poids de chaque modalité plutôt que de compter les lignes.

```
df.groupby("statut")["poids"].sum() / df["poids"].sum()
```

Une conséquence désagréable

La pondération complique aussi l'inférence : les erreurs-types calculées comme si l'échantillon était aléatoire simple sont sous-estimées, parfois nettement.

Un traitement rigoureux exige de connaître le plan de sondage — strates, grappes, degrés.

Ce que nous ferons

Nous pondérons les moyennes et les proportions, et nous signalons que les erreurs-types sont approximatives. C'est la pratique courante en travail appliqué, et elle doit être *dite*, non dissimulée.

Le tableau de comparaison

Le tableau que contient tout article empirique

	Groupe A	Groupe B	Écart
Revenu mensuel	2 140 (980)	1 880 (860)	260 [95 ; 425]
Âge	41,2 (11,4)	39,8 (12,1)	1,4 [−0,3 ; 3,1]
Observations	1 842	1 516	

Entre parenthèses : l'**écart-type**, qui décrit la dispersion des individus.

Entre crochets : l'**intervalle de confiance** de l'écart, qui décrit l'incertitude sur la moyenne.

Ce ne sont pas les mêmes objets, et les confondre est l'erreur la plus fréquente.

Écart-type et erreur-type

```
ecart_type = df["revenu"].std()
n           = df["revenu"].count()
erreur_type = ecart_type / np.sqrt(n)
```

- L'**écart-type** ne diminue pas quand l'échantillon grandit. Il décrit les individus.
- L'**erreur-type** diminue en $1/\sqrt{n}$. Elle décrit la précision de l'estimation.

Avec 40 000 observations, l'erreur-type devient minuscule alors que la dispersion des revenus reste énorme. Les deux informations sont vraies et disent des choses différentes.

Construire le tableau

```
df.groupby("groupe")["revenu"].agg(["mean", "std", "count"])
```

```
# Intervalle de confiance a 95 % d'une moyenne  
moyenne + np.array([-1.96, 1.96]) * erreur_type
```

Le 1,96 vaut pour un échantillon suffisamment grand. En dessous d'une trentaine d'observations par groupe, il faut la loi de Student — mais vos échantillons d'enquête n'auront jamais ce problème.

Ce qu'un intervalle de confiance dit, et ne dit pas

La formulation correcte

Si l'on répétait l'enquête un grand nombre de fois, 95 % des intervalles ainsi construits contiendraient la vraie valeur.

La formulation fausse, et très répandue

« Il y a 95 % de chances que la vraie valeur soit dans cet intervalle. »

La vraie valeur n'est pas aléatoire : elle est fixe et inconnue. C'est l'intervalle qui varie d'un échantillon à l'autre.

La distinction paraît scolastique. Elle est la raison pour laquelle un intervalle ne permet pas de dire ce qui est « probablement vrai ».

Une fonction, pas trois copier-coller

Vous produirez ce tableau pour plusieurs variables. Écrivez-le une fois.

```
def resume(data, variable, groupe, poids=None):  
    g = data.groupby(groupe)[variable]  
    out = g.agg(["mean", "std", "count"])  
    out["err_type"] = out["std"] / np.sqrt(out["count"])  
    out["ic_bas"] = out["mean"] - 1.96 * out["err_type"]  
    out["ic_haut"] = out["mean"] + 1.96 * out["err_type"]  
    return out.round(2)  
  
resume(df, "revenu", "groupe")
```

C'est la fonction écrite en séance 3, appliquée à un autre problème. Vous la réutiliserez au TD 5, puis pour votre mémoire.

Comparer deux groupes

La différence de moyennes

```
from scipy import stats

a = df.loc[df["groupe"] == "A", "revenu"]
b = df.loc[df["groupe"] == "B", "revenu"]

stats.ttest_ind(a, b, equal_var=False)
```

Écrivez toujours `equal_var=False`. C'est le test de Welch, qui ne suppose pas les variances égales.

On enseigne parfois de tester d'abord l'égalité des variances pour choisir le test. Cette pratique est déconseillée : le pré-test déforme le niveau du test final. Welch fonctionne dans les deux cas.

Ce qu'une p-value dit, et ne dit pas

Ce qu'elle est

La probabilité d'observer un écart au moins aussi grand que celui-ci, *si* les deux populations avaient la même moyenne.

- Ce n'est pas la probabilité que l'hypothèse nulle soit vraie.
- Ce n'est pas la probabilité que le résultat soit dû au hasard.
- Une p-value de 0,04 et une de 0,06 ne décrivent pas deux mondes différents.

Rapportez l'écart estimé et son intervalle de confiance. La p-value seule ne renseigne sur rien d'économique.

Significatif ne veut pas dire important

Avec 40 000 observations par groupe, un écart de salaire de 25 euros par mois — 1 % du salaire moyen — est statistiquement significatif.

Il n'a aucune signification économique.

Question	Réponse fournie par
L'écart est-il distinguable de zéro ?	la p-value
De quelle taille est-il ?	l'estimation ponctuelle
Avec quelle précision le connaît-on ?	l'intervalle de confiance
Est-il important ?	l'économie, pas la statistique

La dernière ligne est celle qu'on attend de vous.

Deux variables qualitatives

```
tableau = pd.crosstab(df["diplome"], df["statut"])  
stats.chi2_contingency(tableau)
```

Le test du khi-deux répond à une seule question : les deux variables sont-elles indépendantes dans la population ?

Dans cet ordre

Le tableau croisé se regarde *après* le test, pas avant. Conclure à l'indépendance parce que deux pourcentages se ressemblent, puis chercher un test qui confirme, inverse la démarche — et l'œil n'est pas un instrument de mesure.

Une limite du khi-deux

Le test dit si les variables sont liées. Il ne dit ni dans quel sens, ni avec quelle force, ni pourquoi.

Sur un grand échantillon, il rejette presque toujours l'indépendance — pour la même raison qu'un écart de 25 euros devient significatif.

Ce qui est plus informatif

Les proportions conditionnelles, ligne par ligne : quelle part de chaque niveau de diplôme se trouve au chômage. Le tableau parle davantage que le test.

Nous verrons en séance 7 comment traiter la même question en gardant une mesure d'ampleur.

Pour la suite

- Déciles, rapport interdécile, indice de Gini
- Le tableau de comparaison entre deux groupes, avec intervalles de confiance
- L'ensemble refait sans pondération, pour mesurer le biais

L'écart entre les versions pondérée et non pondérée sera plus grand que ce que la plupart d'entre vous anticipent. C'est le résultat à retenir de la séance.

Contrôle continu

Une heure, sur papier, sans machine. Date et périmètre précis annoncés sur le site du cours.

- Lecture de sortie — un tableau de comparaison vous est donné
- Diagnostic — un extrait de code ou de données contient un problème
- Interprétation — que permet de conclure cet écart, et sous quelles conditions
- Code court — trois à cinq lignes

Deux questions au moins porteront sur une **décision à justifier**. Il n'y a pas de bonne réponse unique ; c'est la justification qui est notée.

`stefaniamarcassa.github.io/analyse_des_donnees`

Des questions ?