

Décrire, comparer, conclure

Analyse des données — Séance 5

Stefania Marcassa

CY Cergy Paris Université — L3 Économie

Où nous allons aujourd'hui

1. Décrire une distribution sans se faire piéger par elle.
2. Décrire par groupe : `groupby`, et l'effectif qu'on oublie.
3. Pondérer, parce qu'une enquête n'est pas un recensement.
4. Construire le tableau que contient tout article empirique.
5. Comparer deux groupes, et dire ce que la comparaison autorise à conclure.

Le fil de la séance

Un chiffre sans son effectif, sa dispersion et son incertitude n'est pas un résultat.

Décrire une distribution

Trois nombres, trois questions différentes

```
df["revenu"].describe()
```

- La **moyenne** répond à : quel est le total, réparti également ?
- La **médiane** répond à : où se situe la personne du milieu ?
- Les **quantiles** répondent à : quelle est la forme de la distribution ?

Sur les revenus, moyenne et médiane s'écartent systématiquement. Ce n'est pas un défaut des données : c'est l'asymétrie de la distribution, et c'est un fait économique.

Rapporter une moyenne sans la médiane sur une variable asymétrique est une faute.

Les points problématiques

Toutes les observations ne se valent pas. Certaines enrichissent l'analyse, d'autres la faussent.


Les points problématiques sont ceux qui se tiennent anormalement loin des autres — souvent des maximums ou des minimums extrêmes. Avant toute analyse, il faut les examiner.

Trois types, à ne pas confondre

1. Les **valeurs extrêmes**
2. Les **points atypiques**
3. Les **points influents**

Ils ne se repèrent pas de la même façon, et ne se traitent pas de la même façon.

Les distinguer : deux critères



Valeur extrême

L'observation est loin des autres, mais reste dans la logique d'ensemble. Elle *n'appartient peut-être pas* à la population étudiée.

Point atypique

Sa position en X est ordinaire, mais son Y s'écarte. Une **variable explicative manque** au modèle.

Point influent

Loin en X et hors tendance. Il **baise le résultat** : la pente passe ici de 42 à 7.

Pourquoi ce point est-il là ?

L'origine du point détermine son traitement.

Erreur manifeste → corriger

Une note de 150 sur 20.

Variable omise → l'ajouter

Un logement bien plus cher à surface égale :
l'emplacement.

Hors population → retirer

Une Ferrari dans une étude sur la puissance du
moteur.

Dans la population → garder



Le supprimer reviendrait à décrire une population
dont on a retiré ce qui dérange.

En cas de doute

Présentez le résultat **avec** le point, **sans** lui, et **avec lui corrigé**. C'est plus honnête qu'un arbitrage caché.

Détecter : regarder d'abord

```
plt.hist(df["SALAIRE_NET"], 30)
df.boxplot(column="SALAIRE_NET", vert=False)
plt.scatter(df["AGE"], df["SALAIRE_NET"])
```



L'**histogramme** donne la forme :
asymétrie à droite, et un **pic**
isolé à 10 000 €.

La **boîte** signale tout ce qui
dépasse la moustache — ici une
masse entière.

Le **nuage** montre que ces points
existent à tous les âges.

On commence toujours par les graphiques. La règle chiffrée vient *ensuite*.

Détecter : la règle de l'écart interquartile

```
s = df["SALAIRE_NET"]
q1, q3 = s.quantile([.25, .75])
iqr = q3 - q1

bas = q1 - 1.5 * iqr
haut = q3 + 1.5 * iqr

print(round(bas), round(haut))
print((s < bas).sum(), (s > haut).sum())
```

Sortie

```
q1 = 1654    q3 = 3155
IQR = 1501

-597    5406
0       269
```

Vers le haut : **269 salaires** signalés, dont le plus faible gagne 5 407 euros — un salaire de cadre, pas une anomalie.

Vers le bas, elle ne signale rien

Le seuil bas est **négatif** : l'écart interquartile dépasse la distance entre q_1 et zéro. Le plus petit salaire, 277 euros, passe inaperçu. **La règle est symétrique, la distribution ne l'est pas.**

Retirer ? Le test du « avec et sans »

moyenne avec, puis sans, les 269 salaires signalés
2610 2406

Les retirer ferait baisser la moyenne de **204 euros**, soit 8 %. Sur un indice d'inégalité, l'effet serait bien plus fort : c'est le haut de la distribution qui le fabrique.

Le coefficient 1,5 ne repose sur aucune théorie : c'est le choix de celui qui a dessiné la boîte à moustaches.

La règle de conduite

La règle de l'écart interquartile sert à **regarder**, jamais à supprimer automatiquement.

Décrire par groupe

Du niveau individuel au niveau groupe

```
df.groupby("SECTEUR").agg(  
    salaire_moyen = ("SALAIRE_NET", "mean"),  
    salaire_median = ("SALAIRE_NET", "median"),  
    effectif       = ("SALAIRE_NET", "count")  
)
```

Trois opérations en une : **découper** selon une clé, **appliquer** un calcul à chaque morceau, **recoller** les résultats.

L'unité statistique a changé. Une ligne ne décrit plus un poste mais un secteur. Tout ce qui suit doit en tenir compte.

Le piège de l'effectif

```
df.groupby("AGE")["SALAIRE_NET"].agg(["mean", "count"])  
    .sort_values("mean", ascending=False).head(3)
```

AGE	Salaire moyen	Effectif
68	4 167	7
52	3 173	159
60	3 159	101

Les 68 ans arrivent en tête — avec **sept** observations. Le classement mesure surtout la taille des groupes.

La règle

Un tableau agrégé s'accompagne **toujours** de l'effectif de chaque groupe.

Pondérer, comparer

Pondérer : une enquête n'est pas un recensement

Enquete Emploi : taux de chômage, sans puis avec les poids
7.95 % 7.44 %

Les personnes interrogées ne sont pas un échantillon miniature de la France : certaines catégories sont volontairement sur-représentées. La variable EXTRIAN dit **combien de personnes chaque répondant représente**.

C'est le taux pondéré qui correspond au chiffre publié par l'INSEE.

La formule à retenir

Compter les lignes décrit **l'échantillon**. Sommer les poids décrit **la population**.

Une conséquence désagréable : les erreurs-types calculées comme si l'échantillon était aléatoire simple sont sous-estimées. Nous pondérons les moyennes, et nous le *disons*.

Le tableau que contient tout article empirique

```
err = lambda x: x.std() / np.sqrt(x.count())
```

```
df.groupby("SEXE").agg(  
    moyenne      = ("SALAIRE_NET", "mean"),  
    ecart_type   = ("SALAIRE_NET", "std"),  
    erreur_type  = ("SALAIRE_NET", err),  
    effectif     = ("SALAIRE_NET", "count"))
```

	Moyenne	Écart-type	Effectif	IC à 95 %
Hommes	2 781	1 494	3 345	[2 730 ; 2 831]
Femmes	2 444	1 416	3 467	[2 397 ; 2 492]

Écart-type : la dispersion *des individus*. **Erreur-type** : l'incertitude *sur la moyenne*, soit l'écart-type divisé par $\sqrt{n}$.

Un intervalle à 95 % dit : en refaisant l'enquête bien des fois, 95 % des intervalles ainsi construits contiendraient la vraie moyenne. Il ne dit **pas** qu'elle a 95 % de chances d'être dans celui-ci.

Comparer deux groupes

```
hommes = df[df["SEXE"] == 1]["SALAIRE_NET"].dropna()
femmes = df[df["SEXE"] == 2]["SALAIRE_NET"].dropna()
```

```
stats.ttest_ind(hommes, femmes, equal_var=False)    # test de Welch
```

```
ecart 336 EUR          IC [267 ; 406]          p = 2e-21
```

`equal_var=False` demande le **test de Welch**, qui ne suppose pas la même dispersion dans les deux groupes. C'est le choix par défaut à retenir.

Ce que la p-value dit : si les deux moyennes étaient égales, un tel écart serait très improbable. **Ce qu'elle ne dit pas** : que l'écart est important, ni qu'il est dû au sexe — diplômes, secteurs et temps de travail différent aussi.

Significatif ne veut pas dire important

Avec 40 000 observations par groupe, un écart de **25 euros** par mois — 1 % du salaire — serait significatif. La p-value dit si l'écart se distingue de zéro ; **seule l'économie dit s'il compte.**

Pour la suite

- Déciles, rapport interdécile, indice de Gini
- Le tableau de comparaison entre deux groupes, avec intervalles de confiance
- L'ensemble refait sans pondération, pour mesurer le biais

L'écart entre les versions pondérée et non pondérée sera plus grand que ce que la plupart d'entre vous anticipent. C'est le résultat à retenir de la séance.

Contrôle continu

Une heure, sur papier, sans machine. Date et périmètre précis annoncés sur le site du cours.

- Lecture de sortie — un tableau de comparaison vous est donné
- Diagnostic — un extrait de code ou de données contient un problème
- Interprétation — que permet de conclure cet écart, et sous quelles conditions
- Code court — trois à cinq lignes

Deux questions au moins porteront sur une **décision à justifier**. Il n'y a pas de bonne réponse unique ; c'est la justification qui est notée.

`stefaniamarcassa.github.io/analyse_des_donnees`

Des questions ?