Visualisation de données économiques

Analyse des données — Séance 6

Stefania Marcassa

CY Cergy Paris Université — L3 Économie

Où nous allons aujourd'hui

Un graphique n'est pas une illustration : c'est un **argument**. Il affirme quelque chose, et il peut mentir sans qu'aucune valeur soit fausse.

1. Quel graphique pour quelle question.
2. Quatre procédés qui trompent — et qu'on rencontre tous les jours.
3. Ce qu'il faut vérifier avant de croire une figure, y compris la sienne.

Le fil de la séance

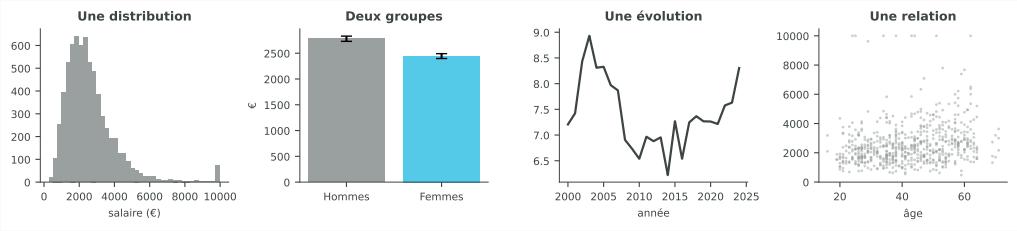
Toutes les figures de cette séance sont justes. Aucune n'est honnête.

Quel graphique pour quelle question

Quatre questions, quatre graphiques

```
plt.hist(s, bins=40)
plt.bar(groupes, moyennes)
    SALAIRE_NET"])
```

```
plt.plot(annees, taux)
plt.scatter(df["AGE"], df["
```



Comment se répartit ?

Histogramme ou boîte.

Qui gagne plus ?

Barres, avec l'incertitude.

Comment ça évolue ?

Courbe.

Vont-elles ensemble ?

Nuage de points.

Le choix se fait sur la question, jamais sur l'esthétique.

Trois erreurs de choix, et ce qu'elles coûtent

On voulait	On a tracé	Ce qui est perdu
Montrer une distribution	Une barre avec la moyenne	Toute la dispersion : deux distributions très différentes donnent la même barre
Comparer deux groupes	Deux camemberts	L'œil compare mal les angles ; les effectifs disparaissent
Montrer une évolution	Des barres côte à côte	La continuité du temps, et donc la tendance

Le camembert

Il ne convient qu'à une chose : montrer qu'une part domine largement. Dès qu'il faut comparer des tranches voisines, une barre horizontale fait mieux.

Comment un graphique trompe

L’axe tronqué

```
ax.bar(["Hommes", "Femmes"], g["mean"])
ax.set_ylim(0, 2900)          # puis 2350 a la place de 0
```



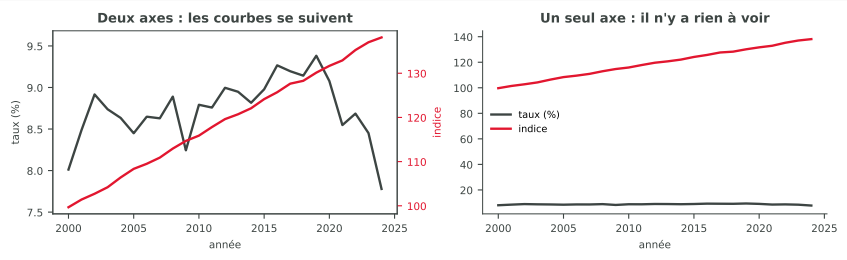
Mêmes données. L’écart vaut **336 euros**, soit 12 % : considérable, mais sans rapport avec la figure de droite.

La règle

Sur des **barres**, l’axe commence à zéro. Sur une **courbe**, tronquer est légitime — on y lit une variation, pas une longueur.

Le double axe

```
a.plot(an, taux)
b = a.twinx()          # <- le second axe, et tout change
b.plot(an, indice)
```



Corrélation réelle : **0,19**. À gauche elles semblent se suivre — il a suffi de choisir deux échelles.

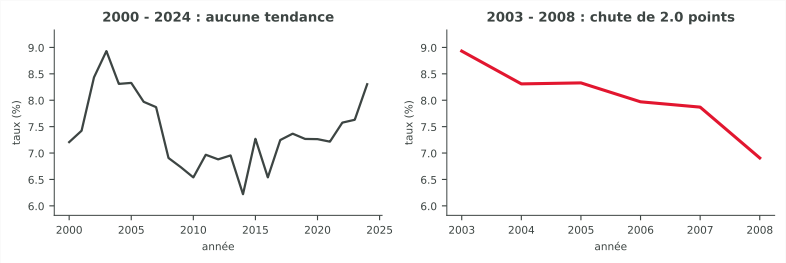
Pourquoi c’est redoutable

Avec deux axes libres, on fait coïncider presque n’importe quelles séries. Aucune valeur n’est fausse.

La parade : un seul axe, ou des séries en base 100.

La période choisie

```
ax.plot(annees, taux)                    # tout
ax.plot(annees[3:9], taux[3:9])          # 2003 - 2008
```



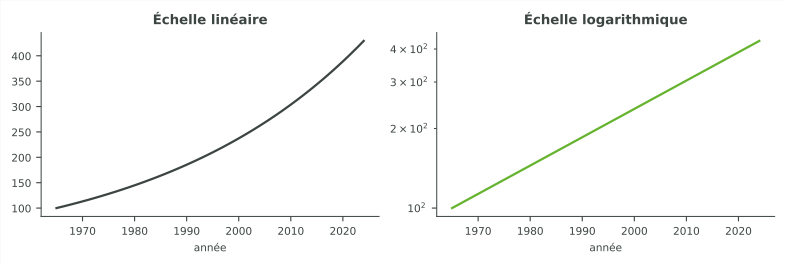
Même série. Sur vingt-cinq ans elle *monte* de 1,1 point ; sur six années choisies, elle chute de 2 points. Les deux figures sont exactes.

Ce qu'il faut exiger

Toute figure temporelle doit dire **pourquoi cette période**. Si les bornes changent la conclusion, c'est le choix qui fait la conclusion.

Linéaire ou logarithmique

```
ax.plot(annees, pib)
ax.set_yscale("log")          # <- une ligne, une autre histoire
```



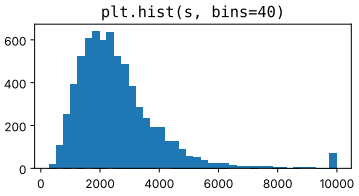
Croissance de 2,5 % par an pendant soixante ans. À gauche l'accélération paraît récente ; à droite, la droite révèle que le taux n'a jamais changé.

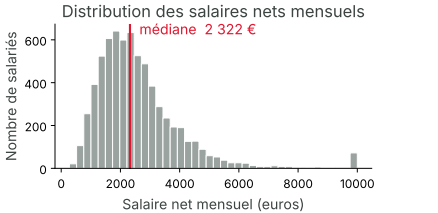
Quand passer au logarithme

Dès qu'on s'intéresse à des **taux de croissance** : une pente constante y signifie un taux constant.

Faire une figure, maintenant

La même figure, rendue présentable






```
ax.set_title("Distribution des salaires nets mensuels")
ax.set_xlabel("Salaire net mensuel (euros)")    # l'unite
ax.set_ylabel("Nombre de salaries")
ax.axvline(s.median(), color="red")             # un repere
```

Le test

Un **titre**, deux **axes nommés avec leur unité**, la **source et le champ** dessous. Si quelqu'un qui n'a pas lu votre texte peut dire **ce qu'elle mesure, sur qui, et d'où viennent les chiffres**, la figure est présentable.

Avant de croire une figure

Quatre questions devant n’importe quel graphique

1. **Où commence l’axe vertical ?** S’il ne part pas de zéro sur des barres, l’écart est exagéré.
2. **Combien d’axes verticaux ?** Deux axes fabriquent des corrélations.
3. **Pourquoi cette période ?** Des bornes choisies produisent la tendance voulue.
4. **Combien d’observations derrière chaque point ?** Une moyenne sur sept personnes se dessine comme une moyenne sur sept mille.

Ces questions valent d’abord pour vos propres figures

Le but n’est pas de débusquer les tricheurs. C’est de ne pas en devenir un par négligence — le cas de loin le plus fréquent.

Pour la suite

TD 6 — Deux courbes de la macroéconomie

- La **courbe de Beveridge** française, sur les données de la DARES : emplois vacants contre chômage. Dater les déplacements de la courbe, et dire ce qu'ils signifient.
- La **courbe de Phillips** sur données longues : inflation contre chômage. Observer qu'une relation stable sur une période disparaît sur une autre.

Deux relations que l'on ne voit qu'en graphique — et dont la lecture dépend entièrement de la période retenue.

Le lien avec aujourd'hui

Vous choisirez vous-mêmes les bornes temporelles. La question 3 de la diapositive précédente deviendra la vôtre.

`stefaniamarcassa.github.io/analyse_des_donnees`

Des questions ?