Régression en pratique I

Analyse des données — Séance 7

Stefania Marcassa

CY Cergy Paris Université — L3 Économie

Où nous allons aujourd'hui

Nous allons construire un modèle **une variable à la fois**, et regarder à chaque étape ce que les coefficients deviennent.

1. Une seule variable explicative, et la sortie qu'elle produit.
2. **Rappel** : ce que teste un t, et ce que dit un p.
3. On ajoute l'expérience. Le coefficient de l'éducation bouge — pourquoi ?
4. On ajoute une **muette**, et la régression devient une comparaison de moyennes.
5. Les **écarts-types robustes** : ce qu'ils changent, ce qu'ils ne changent pas.

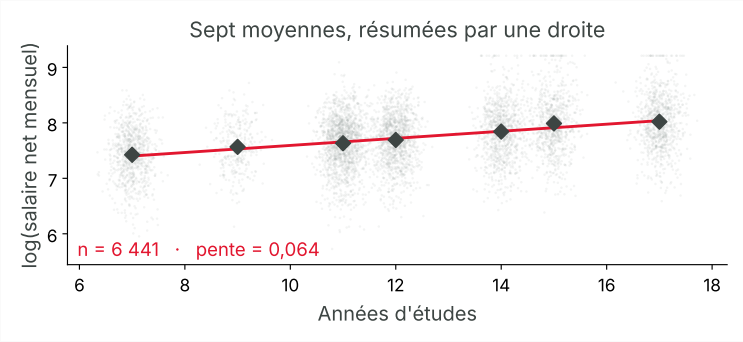
Le fil de la séance

Estimer est facile. Dire ce que le coefficient signifie ne l'est pas — et c'est ce qui est noté.

Une variable

Une droite, et une seule règle

On cherche la droite qui rend la somme des **carrés** des écarts verticaux la plus petite possible.



Les losanges sont les moyennes de salaire à chaque niveau d'études. La droite est l'ajustement pondéré de ces sept moyennes — elle les résume en un seul nombre, et ce résumé a un coût.

Trois lignes, et la sortie qu'elles produisent

```
import statsmodels.formula.api as smf

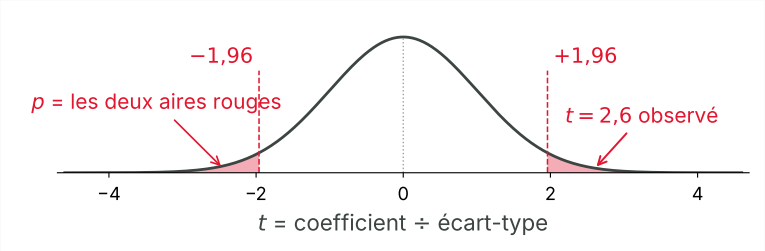
m = smf.ols("LSAL ~ ETUDE", data=d).fit(cov_type="HC1")
print(m.summary())
```

	coef	std err	z	P>|z|	[0.025	0.975]
Intercept	6.9548	0.025	281.65	0.000	6.906	7.003
ETUDE	0.0638	0.002	32.05	0.000	0.060	0.068

- **coef** — de combien la variable expliquée bouge pour une unité de plus.
- **std err** — l'incertitude sur ce nombre. Seule, elle ne se commente pas.
- **P>|z|** — la probabilité d'un coefficient aussi éloigné de zéro si le vrai était nul.
- **L'intervalle** — la plage de valeurs plausibles. C'est elle qu'on cite.

Rappel sur les tests

Ce que teste un t — rappel



- **Hypothèse nulle** : le vrai coefficient vaut zéro. On ne la prouve pas — on regarde si les données la rendent invraisemblable.
- Le t est le **coefficient divisé par son écart-type** : de combien d'écarts-types il s'éloigne de zéro.
- **Trois façons de dire la même chose** : $|t| > 1{,}96 \iff p < 0{,}05 \iff$ l'intervalle de confiance ne contient pas zéro.

Les deux phrases à ne jamais écrire

« p est la probabilité que H_0 soit vraie » — p se calcule *en la supposant* vraie. « Ce n'est pas significatif, donc l'effet est nul » — l'absence de preuve n'est pas la preuve de l'absence.

On ajoute des variables

On ajoute l'expérience

```
f = "LSAL ~ ETUDE + EXPER + I(EXPER**2)"
smf.ols(f, data=d).fit(cov_type="HC1")
```

coefficient de	seule	avec l'expérience
ETUDE	0,0638	0,0716
EXPER	—	0,0162
EXPER^2	—	−0,00014
R^2	0,140	0,196

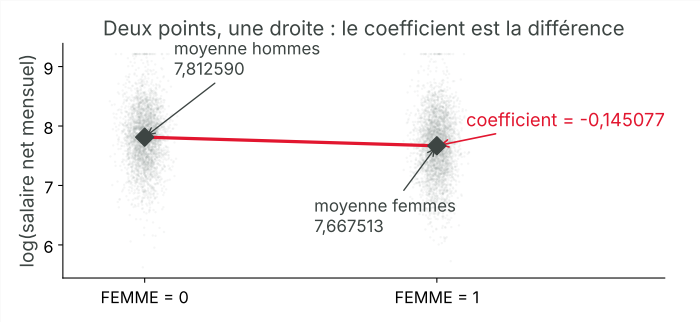
Le rendement de l'éducation **monte**. À âge donné, celui qui a étudié plus longtemps a travaillé moins longtemps : les deux variables sont corrélées négativement par construction (−0,20 ici).

La leçon

La première régression mélangeait deux effets de signe opposé. Un coefficient n'a de sens qu'avec la liste de ce qui est tenu constant à côté.

Les muettes

On ajoute une variable qui ne vaut que 0 ou 1



La droite n'a que deux points où se poser. Elle passe donc exactement par la moyenne de chaque groupe — et sa pente est leur différence.

Si la variable a plus de deux modalités

`C(DIPLOME)` crée $k - 1$ muettes. La modalité omise devient la **référence**, logée dans la constante, et chaque coefficient se lit par rapport à elle. Mettre les k muettes rendrait le modèle inestimable.

Le même nombre, obtenu deux fois

```
d.groupby("FEMME")["LSAL"].mean()          # 7.812590   7.667513
smf.ols("LSAL ~ FEMME", data=d).fit()      # voir ci-dessous
```

	test de moyennes		régression	
moyenne des hommes	7,812590		constante	7,812590
écart femmes – hommes	−0,145077		coefficient	−0,145077
t, variances égales	Student	−11,5366	`.fit()`	−11,5366
t, variances libres	Welch	−11,5518	`cov_type="HC1"`	−11,5518

Ce n'est pas une coïncidence

Tout ce que vous avez appris en séance 5 est un **cas particulier** de la régression. Et le test de Welch n'était rien d'autre qu'un écart-type robuste.

Le modèle complet

Une phrase par coefficient

	coef	std err	z	P>|z|	[0.025	0.975]
Intercept	6.6428	0.032	208.58	0.000	6.580	6.705
ETUDE	0.0721	0.002	37.22	0.000	0.068	0.076
EXPER	0.0161	0.002	9.42	0.000	0.013	0.019
I(EXPER ** 2)	-0.0001	3.25e-05	-4.15	0.000	-0.000	-7.1e-05
FEMME	-0.1518	0.011	-13.53	0.000	-0.174	-0.130

- `ETUDE` — une année d'études de plus est associée à **7,5 %** de salaire en plus ($e^{0{,}0721} - 1$), à expérience et sexe donnés.
- `EXPER` et son carré — une année d'expérience rapporte **1,6 %** en début de carrière, et le gain s'atténue ensuite.
- `FEMME` — à éducation et expérience identiques, les femmes gagnent **14,1 %** de moins.
- `Intercept` — un homme sans études ni expérience : une extrapolation qu'on ne commente pas.

Le R^2 n'est pas une note

0,218 sur données individuelles est **normal** ; 0,95 signalerait une variable qui contient déjà la réponse.

Les écarts-types

Robustes par défaut

```
m = smf.ols("LSAL ~ ETUDE", data=d).fit(cov_type="HC1")
```

	coefficient	se simple	se robuste
`LSAL ~ ETUDE` (en logarithme)	0,0638	0,0020	0,0020
`SALAIRE_NET ~ ETUDE` (en euros)	176,58	5,75	6,02

- **Le coefficient ne bouge jamais.** `cov_type` ne change que l'incertitude — jamais l'estimation.
- En euros, la dispersion des salaires grandit avec le niveau d'études ; en pourcentage, beaucoup moins. Le logarithme absorbe l'essentiel de l'hétéroscédasticité.

La règle de la discipline

`cov_type="HC1"` par défaut. Ce n'est pas de le mettre qui se justifie, c'est de ne pas le mettre.

Pour la suite

Ce qu'un coefficient ne dit pas

Ce qu'on écrit

Une année d'études supplémentaire est **associée** à un salaire supérieur d'environ 7,5 %, à expérience et sexe donnés.

Ce qu'on n'écrit pas

Une année d'études supplémentaire **fait gagner** 7,5 % de salaire.

Ceux qui étudient plus longtemps diffèrent des autres par bien plus que leur diplôme — origine sociale, information, aptitudes. Rien de tout cela n'est dans le fichier, et le coefficient absorbe tout ce qui est corrélé aux deux à la fois.

TD 7 — L'équation de Mincer

Rendement de l'éducation, profil d'expérience, muette de genre, interaction. Une phrase par coefficient : c'est l'exercice, et c'est celui de l'examen.

`stefaniamarcassa.github.io/analyse_des_donnees`

Des questions ?