# Régression en pratique I

## Analyse des données — Séance 7

Stefania Marcassa

CY Cergy Paris Université — L3 Économie

# Où nous allons aujourd'hui

Nous allons construire un modèle **une variable à la fois**, et regarder à chaque étape ce que les coefficients deviennent.

1. Une seule variable explicative, et la sortie qu'elle produit.
2. **Rappel** : ce que teste un $t$, et ce que dit un $p$.
3. On ajoute l'expérience. Le coefficient de l'éducation bouge — pourquoi ?
4. On ajoute une **muette**, et la régression devient une comparaison de moyennes.
5. Les **écarts-types robustes** : ce qu'ils changent, ce qu'ils ne changent pas.

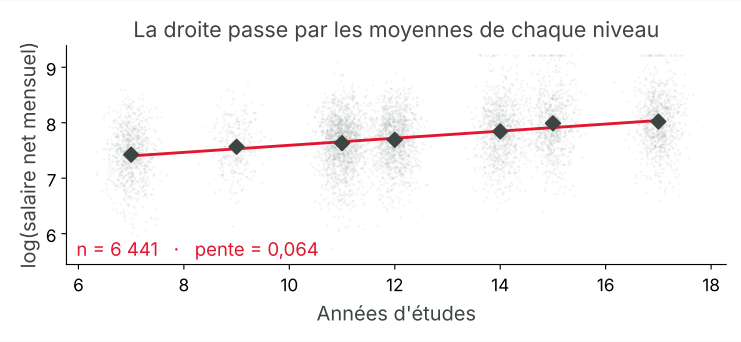
**Le fil de la séance**

Estimer est facile. Dire ce que le coefficient signifie ne l'est pas — et c'est ce qui est noté.

# Une variable

# Une droite, et une seule règle

On cherche la droite qui rend la somme des **carrés** des écarts verticaux la plus petite possible.




Les losanges sont les moyennes de salaire à chaque niveau d'études. La droite les traverse : une régression est une machine à faire des moyennes conditionnelles.

# Trois lignes, et la sortie qu'elles produisent

```
import statsmodels.formula.api as smf

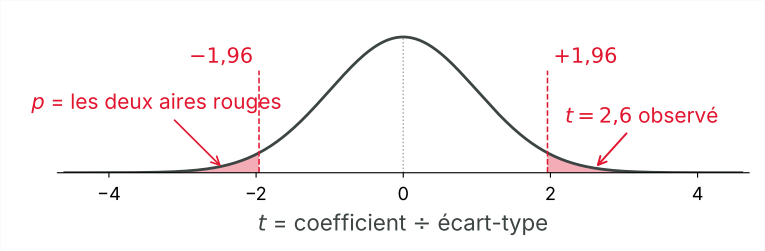
m = smf.ols("LSAL ~ ETUDE", data=d).fit(cov_type="HC1")
print(m.summary())
```

| | coef | std err | z | P>\|z\| | [0.025 | 0.975] |
|---|---|---|---|---|---|---|
| Intercept | 6.9548 | 0.025 | 281.65 | 0.000 | 6.906 | 7.003 |
| ETUDE | 0.0638 | 0.002 | 32.05 | 0.000 | 0.060 | 0.068 |

- **coef** — de combien la variable expliquée bouge pour une unité de plus.
- **std err** — l'incertitude sur ce nombre. Seule, elle ne se commente pas.
- **P>|z|** — la probabilité d'un coefficient aussi éloigné de zéro si le vrai était nul.
- **L'intervalle** — la plage de valeurs plausibles. C'est elle qu'on cite.

# Rappel sur les tests

# Ce que teste un $t$ — rappel




- **Hypothèse nulle** : le vrai coefficient vaut zéro. On ne la prouve pas — on regarde si les données la rendent invraisemblable.
- Le $t$ est le **coefficient divisé par son écart-type** : de combien d'écarts-types il s'éloigne de zéro.
- **Trois façons de dire la même chose** : $|t| > 1{,}96 \iff p < 0{,}05 \iff$ l'intervalle de confiance ne contient pas zéro.

## Les deux phrases à ne jamais écrire

« $p$ est la probabilité que $H_0$ soit vraie » — $p$ se calcule *en la supposant* vraie. « Ce n'est pas significatif, donc l'effet est nul » — l'absence de preuve n'est pas la preuve de l'absence.

# On ajoute des variables

# On ajoute l'expérience

```
f = "LSAL ~ ETUDE + EXPER + I(EXPER**2)"
smf.ols(f, data=d).fit(cov_type="HC1")
```

| coefficient de | seule | avec l'expérience |
|---|---|---|
| ETUDE | 0,0638 | 0,0716 |
| EXPER | — | 0,0162 |
| $\text{EXPER}^2$ | — | −0,00014 |
| $R^2$ | 0,140 | 0,196 |

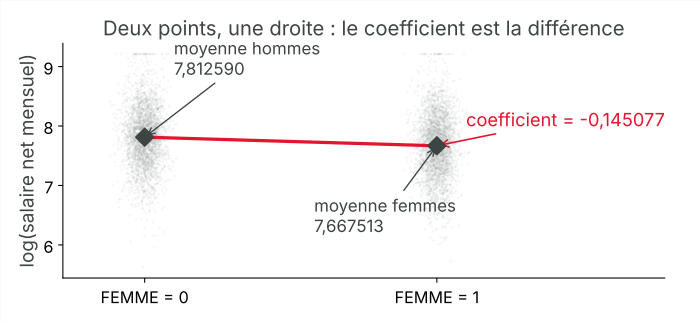
Le rendement de l'éducation **monte**. À âge donné, celui qui a étudié plus longtemps a travaillé moins longtemps : les deux variables sont corrélées négativement par construction (−0,20 ici).

**La leçon**

La première régression mélangeait deux effets de signe opposé. Un coefficient n'a de sens qu'avec la liste de ce qui est tenu constant à côté.

# Les muettes

# On ajoute une variable qui ne vaut que 0 ou 1




La droite n'a que deux points où se poser. Elle passe donc exactement par la moyenne de chaque groupe — et sa pente est leur différence.

**Si la variable a plus de deux modalités**

`C(DIPLOME)` crée $k - 1$ muettes. La modalité omise devient la **référence**, logée dans la constante, et chaque coefficient se lit par rapport à elle. Mettre les $k$ muettes rendrait le modèle inestimable.

# Le même nombre, obtenu deux fois

```
d.groupby("FEMME")["LSAL"].mean()          # 7.812590   7.667513
smf.ols("LSAL ~ FEMME", data=d).fit()      # voir ci-dessous
```

| | test de moyennes | | régression | |
|---|---|---|---|---|
| moyenne des hommes | 7,812590 | | constante | 7,812590 |
| écart femmes – hommes | −0,145077 | | coefficient | −0,145077 |
| $t$, variances égales | Student | −11,5366 | `.fit()` | −11,5366 |
| $t$, variances libres | Welch | −11,5518 | `cov_type="HC1"` | −11,5518 |

**Ce n'est pas une coïncidence**

Tout ce que vous avez appris en séance 5 est un **cas particulier** de la régression. Et le test de Welch n'était rien d'autre qu'un écart-type robuste.

# Le modèle complet

# Une phrase par coefficient

| | coef | std err | z | P>\|z\| | [0.025 | 0.975] |
|---|---|---|---|---|---|---|
| Intercept | 6.6428 | 0.032 | 208.58 | 0.000 | 6.580 | 6.705 |
| ETUDE | 0.0721 | 0.002 | 37.22 | 0.000 | 0.068 | 0.076 |
| EXPER | 0.0161 | 0.002 | 9.42 | 0.000 | 0.013 | 0.019 |
| I(EXPER ** 2) | -0.0001 | 3.25e-05 | -4.15 | 0.000 | -0.000 | -7.1e-05 |
| FEMME | -0.1518 | 0.011 | -13.53 | 0.000 | -0.174 | -0.130 |

- `ETUDE` — une année d'études de plus est associée à **7,5 %** de salaire en plus ($e^{0{,}0721} - 1$), à expérience et sexe donnés.
- `EXPER` et son carré — une année d'expérience rapporte **1,6 %** en début de carrière, et le gain s'atténue ensuite.
- `FEMME` — à éducation et expérience identiques, les femmes gagnent **14,1 %** de moins.
- `Intercept` — un homme sans études ni expérience : une extrapolation qu'on ne commente pas.

**Le $R^2$ n'est pas une note**

0,218 sur données individuelles est **normal** ; 0,95 signalerait une variable qui contient déjà la réponse.

# Les écarts-types

# Robustes par défaut

```
m = smf.ols("LSAL ~ ETUDE", data=d).fit(cov_type="HC1")
```

| | coefficient | se simple | se robuste |
|---|---|---|---|
| `LSAL ~ ETUDE` (en logarithme) | 0,0638 | 0,0020 | 0,0020 |
| `SALAIRE_NET ~ ETUDE` (en euros) | 176,58 | 5,75 | 6,02 |

- **Le coefficient ne bouge jamais.** `cov_type` ne change que l'incertitude — jamais l'estimation.
- En euros, la dispersion des salaires grandit avec le niveau d'études ; en pourcentage, beaucoup moins. Le logarithme absorbe l'essentiel de l'hétéroscédasticité.

**La règle de la discipline**

`cov_type="HC1"` par défaut. Ce n'est pas de le mettre qui se justifie, c'est de ne pas le mettre.

# Pour la suite

# Ce qu'un coefficient ne dit pas

**Ce qu'on écrit**

Une année d'études supplémentaire est **associée** à un salaire supérieur d'environ 7,5 %, à expérience et sexe donnés.

**Ce qu'on n'écrit pas**

Une année d'études supplémentaire **fait gagner** 7,5 % de salaire.

Ceux qui étudient plus longtemps diffèrent des autres par bien plus que leur diplôme — origine sociale, information, aptitudes. Rien de tout cela n'est dans le fichier, et le coefficient absorbe tout ce qui est corrélé aux deux à la fois.

**TD 7 — L'équation de Mincer**

Rendement de l'éducation, profil d'expérience, muette de genre, interaction. Une phrase par coefficient : c'est l'exercice, et c'est celui de l'examen.

`stefaniamarcassa.github.io/analyse_des_donnees`

# Des questions ?