Prévoir

Avec les moindres carrés — Séance 9

Stefania Marcassa

CY Cergy Paris Université — L3 Économie

Où nous allons aujourd'hui

Depuis huit séances, vous cherchez à **expliquer** : quel est l'effet de l'éducation sur le salaire, de la commune sur le prix. Aujourd'hui, on change de question — sans changer d'outil.

1. **Expliquer** et **prévoir** ne sont pas le même exercice, ni le même critère.
2. Le **protocole** : apprentissage, test, repère.
3. Le **surajustement** — et il n'attend pas les modèles compliqués.
4. Ce qu'on arrive à prévoir, et ce qu'on n'arrive pas à prévoir.

Le fil de la séance

Tout se fait aujourd'hui avec la régression que vous connaissez déjà. La semaine prochaine, on ne changera *que* l'estimateur — et vous verrez que le protocole, lui, ne bouge pas.

Expliquer n’est pas prévoir

Deux questions, deux critères

	Expliquer	**Prévoir**
La question	Quel est l'effet de x sur y ?	Quelle sera la valeur de y ?
Ce qu'on regarde	**un coefficient**, son signe, son écart-type	**une erreur**, sur des données jamais vues
Ce qui compte	que le modèle soit *juste*	que la prévision soit *bonne*
Les variables	peu, choisies, interprétables	autant qu'on veut, même opaques
Le R^2	accessoire	inutile s'il est calculé sur les données d'apprentissage

Le même outil peut servir aux deux — pas de la même façon

Une régression dont aucun coefficient n'est interprétable peut très bien prévoir. Et un modèle qui prévoit mal peut parfaitement établir un effet causal.

Le piège : un R^2 de 0,99

```
smf.ols("prix_demain ~ prix_aujourdhui", data=d).fit()
```

R^2 du modèle	0,993
Erreur du modèle estimé	3,615 €
Erreur de la règle « demain = aujourd'hui »	3,619 €
Gain du modèle sur une règle sans paramètre	0,11 %

Le R^2 ne mesurait pas la qualité de la prévision : il mesurait la **persistance de la série**. Un cours de bourse bouge peu d'un jour à l'autre — l'expliquer à 99 %, c'est seulement l'avoir remarqué.

La règle qui en découle

Un modèle de prévision **n'existe pas sans son repère**, et le repère doit être honnête : la règle la plus bête qui réponde à la même question.

Le protocole

Découper dans le temps, jamais au hasard

```
c = int(len(d) * 0.8)
apprentissage, test = d.iloc[:c], d.iloc[c:]
```

- On estime sur le **passé**, on évalue sur l'**avenir**. Découper au hasard entraînerait le modèle sur 2025 pour prédire 2021 : aucun praticien ne dispose jamais de cette information.
- Deuxième raison, moins connue : les variables à fenêtres glissantes **se chevauchent**. Mélanger place dans l'apprentissage des observations quasi identiques à celles du test.
- Toute variable doit être **disponible la veille au soir**. D'où le `.shift(1)` devant chaque `.rolling()`.

Le protocole ne dépend pas du modèle

Régression aujourd'hui, arbre et forêt la semaine prochaine : même découpage, même repère, même critère. C'est ce qui rendra la comparaison possible.

Le R^2 hors échantillon, et son signe

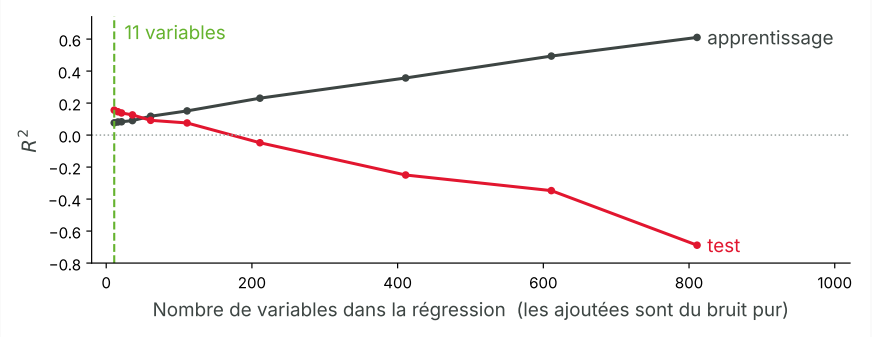
$$R^2_{\text{hors}} = 1 - \frac{\sum (y - \hat{y})^2}{\sum (y - \text{repère})^2}$$

- Le repère n'est **pas** la moyenne des données de test — on ne la connaît pas au moment de prévoir. C'est la moyenne de l'apprentissage, ou zéro quand c'est la valeur naturelle.
- En apprentissage, les moindres carrés garantissent $R^2 \geq 0$. Hors échantillon, il peut être négatif : le modèle fait alors **pire que de ne rien faire**.
- L'écart entre les deux R^2 porte un nom : c'est le **surajustement**. Le modèle a appris du bruit, et le bruit ne se reproduit pas.

Ce qu'on publie

Jamais un R^2 seul. Toujours : sur quelles données il est calculé, contre quel repère, et sur quelle période.

Le surajustement n’attend pas les modèles compliqués



Une **simple régression**, à laquelle on ajoute des variables de **bruit pur**. En apprentissage le R^2 monte de 0,08 à **0,61** — les moindres carrés exploitent le moindre hasard. Sur des données nouvelles il s’effondre à $-0{,}69$. Aucun arbre, aucun réseau de neurones : des moindres carrés ordinaires.

Ce qu’on prévoit, et ce qu’on ne prévoit pas

Prévoir le rendement de demain

R^2 en apprentissage	0,016
R^2 hors échantillon	≈ 0
Séances en hausse dans la période de test	48,0 %
« Toujours en hausse » a raison	48,0 %
Le modèle a raison	48,8 %
Incertitude sur 346 journées	$\pm$ 5,3 points

- Onze variables et mille journées donnent forcément un R^2 d'apprentissage positif. Hors échantillon, il est indistinguable de zéro.
- Sur le **sens**, le modèle ne bat pas une règle fixe — et l'écart est quatre fois plus petit que l'incertitude.

Chiffres du notebook du cours ; ils se rafraîchissent à chaque exécution.

Et pourtant, quelque chose est prévisible

Même code, mêmes variables, même découpage. On change **seulement la cible** : au lieu du rendement, son **amplitude** $|r|$.

Cible	R^2 **apprentissage**	R^2 **hors échantillon**
rendement de demain	0,016	≈ 0
amplitude $\lvert r \rvert$	0,077	$+0{,}156$

- Le **sens** ne peut pas être prévisible : s'il l'était, on achèterait, le prix monterait, et l'occasion disparaîtrait. Un R^2 nul sur les rendements n'est pas un échec — c'est une **confirmation** de l'efficience.
- L'**amplitude** n'offre aucun gain direct : savoir que demain sera agité ne dit pas dans quel sens. Rien ne pousse à l'arbitrer, la régularité subsiste. C'est le regroupement de volatilité du TD.

Toute la gestion du risque vit de cette asymétrie.

La fuite d'information

```
X["vol5"] = r.shift(1).rolling(5).std()      # correct
X["vol5"] = r.rolling(5).std()               # le .shift oublie
```

	R^2 **hors échantillon**
`vol5` correcte	0,156
`vol5` sans le `.shift(1)`	0,380

- La volatilité « des 5 derniers jours » calculée *jour t inclus* contient un cinquième de la cible. Le modèle ne prévoit pas : il **recopie**.
- Aucune erreur, aucun avertissement. Le seul signal est une performance trop belle.
- Le découpage chronologique ne protège pas de cette fuite-là. Les deux précautions sont indépendantes, et toutes deux nécessaires.

Pour la suite

Ce qu'il faut retenir

1. Un R^2 calculé sur les données d'apprentissage ne dit rien de la prévision.
2. Un modèle de prévision se compare à un **repère**, toujours.
3. Sur une série temporelle, le découpage est **chronologique**, et chaque variable doit être disponible la veille.
4. Le surajustement est l'affaire de **tous** les modèles, la régression comprise.
5. Un échec de prévision bien mesuré est un **résultat** : il dit que le marché a déjà intégré ce que nous savons.

Séance 10 — on change l'estimateur, et rien d'autre

Arbre de décision et forêt aléatoire, sur **les mêmes données, le même découpage et les mêmes repères**. La question sera simple : un modèle plus souple trouve-t-il ce que la régression n'a pas trouvé ?

`stefaniamarcassa.github.io/analyse_des_donnees`

Des questions ?