

Environnement et anatomie des données

Analyse des données — Séance 1

Stefania Marcassa

CY Cergy Paris Université — L3 Économie

Le cours

Ce que vous saurez faire en décembre

1. **Trouver et charger** des données économiques réelles, et lire la documentation d'une source.
2. **Nettoyer et restructurer** un jeu de données brut.
3. **Produire des statistiques descriptives défendables.**
4. **Construire des graphiques honnêtes.**
5. **Estimer et lire une régression** en pratique.
6. **Rendre un travail reproductible.**

Le critère

Qu'une autre personne puisse ré-exécuter votre code et retrouver vos résultats.

Ce que ce cours n'est pas

Ce n'est pas un cours d'économétrie théorique. Les propriétés des estimateurs sont supposées connues.

C'est un cours de **mise en œuvre** : la difficulté est dans les données, pas dans les formules.

Une mise en garde, dès aujourd'hui

Une régression ne mesure pas un effet causal. Elle mesure une association conditionnelle aux variables incluses.

Tout le métier tient dans l'écart entre les deux. Nous y reviendrons à chaque séance à partir de la séance 7.

Comment le semestre est organisé

Trois blocs

- Séances 1–5 : manipulation des données
- Séances 6–8 : visualisation et régression
- Séances 9–10 : séries temporelles, synthèse

Chaque TD

- 25 min : retour sur l'exercice, erreurs fréquentes
- 30 min : résolution en direct
- 45 min : travail autonome

Chaque séance donne lieu à trois fichiers sur le site du cours : le **notebook à trous** (avant), le **script complet** (après), l'**exercice** (pour la fois suivante).

Épreuve	Poids	Durée	Périmètre
Contrôle continu	50 %	1 h	Séances 1 à 5
Contrôle terminal	50 %	2 h	Ensemble du cours

Les deux épreuves se déroulent **sur papier, sans machine**.

Aucune ne demande d'écrire du code de mémoire.

Quatre types de questions

1. **Lecture de sortie.** Un tableau ou une régression vous est donné : que montre-t-il, et que ne montre-t-il pas ?
2. **Diagnostic.** Un extrait de données ou de code contient un problème : l'identifier, proposer une correction.
3. **Interprétation économique.** Que peut-on affirmer à partir de ce coefficient, et sous quelles conditions ?
4. **Code court.** Trois à cinq lignes à écrire ou compléter — jamais un script entier.

Ce qui est évalué n'est pas la syntaxe. C'est le **jugement sur les données**.

Autorisés et attendus pour les exercices. C'est l'outil de travail réel de votre future profession.
Interdits lors des deux épreuves, qui se tiennent sans machine.

Ce qu'ils font bien, ce qu'ils font mal

Un assistant écrit très bien la syntaxe.

Il est peu fiable sur les décisions qui font l'objet de ce cours : quelle variable retenir, comment traiter les manquants, quelle spécification est défendable, ce qu'un coefficient autorise à conclure.

Si vous ne pouvez pas expliquer une ligne qu'il a produite, vous ne saurez pas répondre à la question de diagnostic qui portera dessus.

L'environnement de travail

Tout le cours se fait dans le navigateur.

- Aucune installation, aucune version de Python à gérer
- Aucun problème de chemin d'accès
- Un compte Google suffit
- Le code s'exécute sur une machine distante, pas sur la vôtre

Le travail en local (Anaconda, VS Code) est possible mais **non assisté** : les TD ne sont pas consacrés au dépannage d'installations.

Premier notebook — à faire maintenant

1. Connectez-vous à votre compte Google.
2. Allez sur `colab.research.google.com`
3. Cliquez sur **Nouveau notebook**.
4. Utilisez Chrome ou Firefox de préférence.

Un notebook est une suite de **cellules** de deux types :

- les cellules de **code**, que l'on exécute avec Maj + Entrée ;
- les cellules de **texte**, pour commenter ce que l'on fait.

Un notebook sans cellules de texte est un notebook illisible — y compris pour vous, dans trois semaines.

Une première cellule

```
# Le taux de croissance entre deux années  
pib_2023 = 2822  
pib_2024 = 2891  
  
croissance = (pib_2024 - pib_2023) / pib_2023  
print(croissance)  
  
0.024450035435861798
```

Trois choses à retenir : le # introduit un commentaire, le = affecte une valeur, et rien ne s'affiche sans print().

Un piège qui vous coûtera dix minutes

Lors du premier import de fichier, Colab peut renvoyer une erreur si les **cookies tiers** sont bloqués dans votre navigateur.

La correction :

1. Ouvrir les paramètres du navigateur
2. Autoriser `https://[*.]googleusercontent.com:443`

Notez-le maintenant. Vous en aurez besoin à la séance 2.

**Les objets dont nous aurons
besoin**

Quatre types de base

```
inflation = 2.4           # float : nombre a virgule
annee      = 2024          # int   : nombre entier
pays       = "France"     # str   : texte
zone_euro  = True          # bool  : vrai / faux
```

La distinction `int` / `float` paraît anodine. Elle ne l'est pas :

- un identifiant de commune lu comme un `int` perd son zéro initial ;
- une année lue comme un `str` ne se compare pas, ne se trie pas.

La moitié des bugs de ce cours viendra d'un type mal interprété à la lecture d'un fichier.

Listes : une suite ordonnée

```
prix = [1.20, 0.95, 2.40, 1.75]
```

```
prix[0]          # 1.2    -- on compte à partir de zero
```

```
prix[-1]         # 1.75   -- le dernier
```

```
len(prix)        # 4
```

```
sum(prix)        # 6.3
```

L'indexation commence à **zéro**. C'est la source d'erreur la plus fréquente chez les débutants, et elle ne produit pas de message d'erreur : elle produit un résultat faux.

Dictionnaires : des paires clé-valeur

```
panier = {"pain": 1.20, "lait": 0.95, "cafe": 2.40}
```

```
panier["pain"]           # 1.2
```

```
panier.keys()            # les biens
```

```
panier.values()          # les prix
```

Un dictionnaire décrit exactement ce dont nous avons besoin en TD : un **panier de biens**, où chaque bien porte un prix et une quantité.

C'est aussi, en pratique, la structure d'une ligne d'un tableau de données.

Anatomie d'un tableau de données

Trois mots à ne jamais confondre

id_menage	revenu	region
1001	32 400	Île-de-France
1002	28 900	Occitanie
1003	41 200	Bretagne

- Une **observation** : une ligne. Ici, un ménage.
- Une **variable** : une colonne. Ici, le revenu.
- L'**unité statistique** : ce que représente une ligne. Ici, le ménage — et non l'individu.

Pourquoi l'unité statistique est le premier piège

La même question économique change de réponse selon l'unité retenue.

Un exemple

« Quel est le revenu moyen ? »

Par **ménage** : un chiffre. Par **individu** : un autre. Par **unité de consommation** : un troisième.

Aucun n'est faux. Ils ne répondent simplement pas à la même question.

Avant toute analyse : **de quoi une ligne est-elle la description ?**

Trois structures de données

Coupe transversale

Plusieurs unités, une date.

Les salaires de 40 000 individus
en 2023.

Série temporelle

Une unité, plusieurs dates.

Le taux de chômage français,
1975–2025.

Panel

Plusieurs unités, plusieurs
dates.

Le PIB de 27 pays, 2000–2024.

La structure détermine ce que l'on peut estimer — et ce que l'on ne peut pas. Nous construirons un panel à la séance 4.

Pour chacun de ces jeux de données : quelle est l'unité statistique, et quelle est la structure ?

1. Le prix de clôture du CAC 40, chaque jour depuis 1990.
2. Les réponses à l'Enquête Emploi du deuxième trimestre 2024.
3. Les transactions immobilières enregistrées en France de 2014 à 2024.
4. Le taux d'emploi des 27 pays de l'UE, chaque année depuis 2000.

Le cas 3 est moins évident qu'il n'y paraît : discutons-en.

Pour la suite

Nous construirons un indice des prix à la consommation à partir d'un panier de biens pondéré, puis nous comparerons deux façons de le calculer.

- L'indice de **Laspeyres** fixe les quantités à l'année de base.
- L'indice de **Paasche** les fixe à l'année courante.

Les deux mesurent « l'inflation ». Ils ne donnent pas le même chiffre.

Toute la question du TD : **pourquoi**, et lequel choisir.

Avant la séance 2

1. Créez votre compte Google si vous n'en avez pas.
2. Ouvrez un notebook Colab et exécutez une cellule.
3. Autorisez `googleusercontent.com` dans votre navigateur.
4. Récupérez le notebook de la séance 2 sur le site du cours.

`stefaniamarcassa.github.io/analyse_des_donnees`

Des questions ?