Wooclap — corrigé commenté

Analyse des données — L3 Économie — 21 questions

Le pourcentage indiqué à droite de chaque question est la part de bonnes réponses dans la salle. En dessous de 60 %, la question mérite d'être revue : elles sont reprises à la fin de ce document.

Types, environnement, chargement

1. Parmi ces variables, laquelle est un entier (`int`) ? 83 % de bonnes réponses

▶ **Le nombre d'enfants du ménage**

Un entier compte des unités indivisibles. La taille et le taux de chômage sont des décimaux ; le code commune s'écrit avec des chiffres mais ne se calcule pas — c'est une chaîne de caractères, et le charger en nombre détruit le zéro initial de `01053`.

2. Vous corrigez le taux de TVA de 0,20 à 0,055 et vous réexécutez cette seule cellule. `prix_ttc`, calculée plus bas, vaut toujours 120. 74 % de bonnes réponses

▶ `prix_ttc` **n'a pas été recalculée**

Un notebook garde en mémoire le résultat de la dernière exécution de *chaque* cellule. Modifier une cellule ne réexécute pas celles qui en dépendent. D'où la règle : avant toute conclusion, *Exécution → Tout exécuter.*

3. `UnicodeDecodeError: 'utf-8' codec can't decode byte 0xe9` 81 % de bonnes réponses

▶ **Préciser l'encodage au chargement**

L'octet `0xe9` est un « é » en `latin-1`. Le fichier n'est pas abîmé : Python l'a lu avec le mauvais alphabet. `encoding="latin-1"` suffit. Supprimer les accents reviendrait à modifier la source pour contourner un problème de lecture.

4. Un fichier de l'INSEE chargé, et `df.shape` renvoie `(45, 1)`. 65 % de bonnes réponses

▶ **Le séparateur n'est pas la virgule**

Une seule colonne contenant toute la ligne : pandas n'a trouvé aucun séparateur. Les fichiers français utilisent le point-virgule, la virgule servant de séparateur décimal. Un encodage incorrect produirait des accents illisibles, pas une colonne unique.

Filtrer et modifier

5. `df2 = df[(df["POP"] > 50000) & (df["TAUX_CHOMAGE"] > 18)]` 68 % de bonnes réponses

▶ **Un nouveau tableau, restreint aux communes vérifiant les deux conditions**

`&` est le « et » logique : les deux conditions doivent être vraies simultanément. `df` n'est pas modifié — le résultat est affecté à un nouveau nom. Avec `|` on obtiendrait le « ou ».

6. `df.loc[df["POP"] < 2000, "TAUX_CHOMAGE"] = 0` 34 % de bonnes réponses

▶ **Les valeurs sont modifiées comme prévu**

C'est la **bonne** façon d'écrire dans un tableau : `.loc` désigne les lignes *et* la colonne en une seule opération, et modifie `df` lui-même. La version qui échoue silencieusement est `df[df["POP"] < 2000]["TAUX_CHOMAGE"] = 0`, qui écrit dans une copie temporaire aussitôt jetée.

Valeurs manquantes et codes

7. 675 lignes valent 0 (« sans objet, non-salariés ») et 525 valent 999 999 (« non-réponse »). Même traitement ? 87 % de bonnes réponses

▶ **Non : le zéro décrit une situation réelle, le 999 999 une absence de réponse**

Le zéro est une information : la personne n'est pas salariée. Le 999 999 n'en est pas une : la question a été posée, sans réponse. Le second devient `NaN` ; le premier s'écarte du champ si l'on étudie les salariés, mais ce n'est pas une donnée manquante.

8. La valeur 1 859,27 apparaît trois fois dans la colonne des salaires. Est-ce un code de non-réponse ?
74 % de bonnes réponses

▶ **Non : trois salariés peuvent gagner le même montant**

Un code de non-réponse est une valeur *ronde et aberrante*, répétée des centaines de fois, et déclarée dans le dictionnaire. 1 859,27 est un montant plausible avec des centimes : la répétition est une coïncidence ordinaire.

9. `ACTEU` est vide pour toutes les personnes de moins de 15 ans. 86 % de bonnes réponses

▶ **D'un hors champ : la question ne leur a pas été posée**

Le vide est ici parfaitement informatif — la variable n'a pas de sens avant 15 ans. Imputer serait inventer une activité à des enfants. Le hors champ se reconnaît à sa régularité : il suit exactement une règle de l'enquête.

10. Les ménages les plus aisés répondent moins souvent à la question du patrimoine. 57 % de bonnes réponses

▶ **Non au hasard (MNAR)**

La probabilité de ne pas répondre dépend de la valeur que l'on cherche justement à mesurer. Ce n'est pas MAR : aucune variable observée ne « contient » le niveau de patrimoine non déclaré.

11. Dans cette situation, que peut-on faire ? 59 % de bonnes réponses

▶ **Rien : aucune correction n'est possible à partir des seules données observées**

C'est la conséquence directe de MNAR. Supprimer les lignes biaise le résultat vers le bas ; imputer par la moyenne des répondants aussi. Sortir de l'impasse suppose une information extérieure — données fiscales appariées, hypothèse explicite sur la non-réponse.

Définitions et indices

12. 2,33 millions de chômeurs au sens du BIT, 5,85 millions d'inscrits à France Travail. 58 % de bonnes réponses

▶ **Les deux sont exacts et comptent des personnes différentes**

Les deux ensembles se recoupent sans s'emboîter : des chômeurs BIT ne sont pas inscrits, et beaucoup d'inscrits (catégories B et C) ont travaillé dans le mois, ce qui les exclut du chômage BIT. « Les inscrits incluent les chômeurs BIT, plus les inactifs » décrit donc une inclusion qui n'existe pas.

13. Pain $+12{,}5$ %, lait $+7{,}4$ %, café -5 %. Moyenne simple : 4,96 %. Panier réel : 7,46 %. 86 % de bonnes réponses

▶ **Les biens ne pèsent pas le même poids dans le budget**

Une moyenne simple suppose que les trois biens comptent autant. Un indice de prix est une moyenne *pondérée* par la part de chaque bien dans la dépense : le pain, plus acheté, tire l'indice vers le haut.

14. Deux indices de prix calculés sur les mêmes prix ne donnent pas le même chiffre. 59 % de bonnes réponses

▶ **Ils retiennent les quantités d'années différentes**

Les prix sont identiques, les pondérations non. Laspeyres pondère par le panier d'une année de base ; Paasche par celui de l'année courante. L'écart mesure la *substitution* : les ménages délaissent ce qui renchérit.

Dossier documentaire — vrai ou faux

Rappel de l'extrait projeté : dix lignes, six variables. `IDENT` apparaît deux fois pour 01053 et deux fois pour 07186. Non-réponses déclarées : `AGE` = 99, `SALAIRE_NET` = 999 999, `TEMPS` = 9. Les salaires supérieurs à 10 000 € sont ramenés à 10 000 (plafond de diffusion).

15. Le fichier décrit dix personnes. 56 % de bonnes réponses

▶ **Faux**

Dix *lignes*, huit *personnes* : 01053 et 07186 occupent chacun deux postes dans l'année. Confondre les deux conduit à diviser une somme de salaires par le mauvais effectif.

16. `isna()` signale quatre valeurs manquantes dans ce tableau. 42 % de bonnes réponses

▶ **Faux**

`isna()` renvoie **zéro**. Les absences sont codées en nombres — 999 999, 99, 9 — et Python les lit comme des nombres parfaitement valides. Elles ne deviennent manquantes qu'après un `replace` explicite. C'est la raison d'être du dictionnaire.

17. Le code 9 de `TEMPS` est une non-réponse. 67 % de bonnes réponses

▶ **Vrai**

Le dictionnaire le déclare : 1 complet, 2 partiel, 9 non-réponse. À remplacer par `NaN` avant tout comptage, faute de quoi la modalité « 9 » apparaîtra comme un troisième temps de travail.

18. La clé de ce fichier est `IDENT`. 52 % de bonnes réponses

▶ **Faux**

Une clé ne prend jamais deux fois la même valeur ; `IDENT` se répète. La clé est le couple `IDENT` + `NOPOSTE`. C'est aussi la colonne sur laquelle s'appuierait une fusion : la supposer unique produit des doublons silencieux.

19. Les deux salariés à 10 000 € gagnent exactement le même salaire. 64 % de bonnes réponses

▶ **Faux**

10 000 est un **plafond de diffusion** : tous les salaires supérieurs y sont ramenés. On sait seulement que ces deux salariés gagnent *au moins* 10 000 €. Toute moyenne calculée sur cette colonne est une borne inférieure, et tout indice d'inégalité est sous-estimé.

20. Un salaire de 0 € est nécessairement une erreur de saisie. 67 % de bonnes réponses

▶ **Faux**

Le zéro code ici « sans objet » — la personne n'est pas salariée. C'est une situation réelle, pas une erreur. Elle doit sortir du champ quand on étudie les salaires, mais pas être corrigée.

21. `REGION` peut être chargée comme un nombre sans risque. 60 % de bonnes réponses

▶ **Faux**

Le dictionnaire la déclare de type caractère. Un code de région ne s'additionne pas et ne se compare pas ; chargé en nombre, il perd ses zéros initiaux, ce qui fait échouer toute fusion ultérieure avec un fichier où ils sont conservés.

Les cinq points à retravailler

Q	Réussite	Ce qu'il faut retenir
6	34 %	`.loc` est la bonne écriture pour modifier. C'est l'indexation en chaîne, `df[...][...]`, qui échoue sans message.
16	42 %	`isna()` ne voit pas les codes numériques. Zéro manquant détecté ne signifie pas zéro manquant.
18	52 %	Une clé est unique. `IDENT` seul ne l'est pas : une personne peut occuper plusieurs postes.
15	56 %	Une ligne n'est pas une personne. Toujours se demander ce que décrit une ligne avant d'agréger.
10	57 %	MNAR : la non-réponse dépend de la valeur cherchée. Les données seules ne permettent pas de corriger.

Quatre de ces cinq questions portent sur le même réflexe : **lire le dictionnaire avant de calculer**. Une valeur numérique n'est pas une valeur mesurée tant qu'on n'a pas vérifié ce qu'elle code.