Wooclap — partie 2, corrigé commenté

Analyse des données — L3 Économie — banque de 39 questions

Deux clés à revoir avant de reprojeter ce questionnaire.

Question 9 (les deux absences). La clé importée indique « inférieur d'environ 240 € ». Vérification faite sur le fichier : mettre *les deux* codes en valeur manquante donne 2 609,6 €, soit exactement la moyenne correcte — `mean()` ignore les `NaN`. Les 2 374 € sont la moyenne de l'étudiant qui corrige le 999 999 mais garde les 675 zéros. Pour retrouver l'intention de la question, remplacer l'énoncé par : « *Un étudiant met le 999 999 en valeur manquante mais conserve les 675 zéros* ».

Question 13 (la conséquence). « Rien n'est possible » ne vaut que sous MNAR. Or la question 12 a été reformulée en un cas où l'on observe seulement que la non-réponse dépend du diplôme : « corriger en tenant compte des variables observées » devient alors au moins aussi juste. Deux issues : revenir à l'énoncé MNAR en 12 (« les ménages les plus aisés répondent moins souvent »), ou faire de l'option 1 la bonne réponse en 13.

Types, unité statistique, exécution

1. Un code commune est chargé en texte. Quelle opération devient possible, qui serait fausse ou impossible en entier ?

▶ **Extraire le département par** `.str[:2]`

Les accesseurs `.str` n'existent que sur une colonne de texte. Les trois autres opérations marchent sur des entiers comme sur des chaînes. Et en entier, `01053` devient `1053` : le département n'est plus dans les deux premiers caractères.

2. `dvf_2023.csv` contient 2,3 millions de lignes, pour environ un million de transactions par an.

▶ **Une ligne n'est pas une transaction**

Le rapport est trop net pour être fortuit. Dans DVF, une vente peut porter sur plusieurs lots, et chaque lot fait une ligne. Compter les lignes revient à compter plusieurs fois la même vente : la première question devant un fichier est toujours « que décrit une ligne ? ».

3. Vous corrigez le taux de TVA et réexécutez cette seule cellule. `prix_ttc` vaut toujours 120.

▶ `prix_ttc` **n'a pas été recalculée**

Un notebook garde le résultat de la dernière exécution de *chaque* cellule. Modifier une cellule ne réexécute pas celles qui en dépendent. D'où la règle : avant toute conclusion, *Exécution* → *Tout exécuter*.

Diagnostiquer un chargement

4. `UnicodeDecodeError` en position 132 chez vous, en position 0 chez un camarade.

▶ **Chez lui, le premier caractère est accentué ; chez vous, il apparaît plus loin**

La position est celle du premier octet que l'encodage déclaré ne sait pas lire. Elle dépend de l'endroit où tombe le premier accent, pas de la gravité du problème. Même cause, même correction : `encoding="latin-1"`.

5. Premier fichier : `shape = (45, 1)`. Second : `(45, 7)`, accents remplacés par des symboles.

▶ **Le premier a un problème de séparateur, le second d'encodage**

Deux symptômes à ne pas confondre. Une seule colonne : aucun séparateur reconnu, la ligne entière est restée d'un bloc. Le bon nombre de colonnes avec des accents abîmés : la structure a été lue, les caractères non.

6. `CODGEO` est entier d'un côté, texte de l'autre. La fusion échoue ; l'étudiant applique `astype(str)` et relance.

▶ **Une seule : 75056**

`astype(str)` fait taire l'erreur sans régler le problème : `"1053"` et `"01053"` restent deux chaînes différentes. Seuls les codes sans zéro initial s'apparient. La vraie correction est de charger l'identifiant en texte dès le départ

(`dtype=str`), ou de reformater avec `.str.zfill(5)`.

Filtrer et modifier

7. `df[(df["POP"] > 50000) | (df["TAUX_CHOMAGE"] > 18)]`, sur 45 communes dont 16 grandes et 12 à fort chômage.

▶ **Entre 16 et 28**

Avec | (le « ou »), le résultat contient au moins le plus grand des deux groupes et au plus leur somme, selon leur recouvrement. Si les 12 communes à fort chômage étaient toutes parmi les 16 grandes : 16. Si aucune ne l'était : 28.

8. `df[df["POP"] < 2000]["TAUX_CHOMAGE"] = 0`

▶ **La modification s'applique à une copie et disparaît**

`df[...]` produit un extrait temporaire ; on écrit dedans, puis il est jeté. Rien ne change dans `df`, et aucune erreur n'interrompt l'exécution. L'écriture correcte désigne lignes et colonne en une seule opération :

```
df.loc[df["POP"] < 2000, "TAUX_CHOMAGE"] = 0
```

Absences : codes, hors champ, mécanismes

9. 675 lignes à 0 et 525 à 999 999. Un étudiant met les deux en valeur manquante, puis calcule la moyenne.

▶ **Identique (2 610 €) — voir l'avertissement en tête de document**

`mean()` ignore les `NaN`. Mettre les deux codes en manquant laisse exactement les 6 812 salaires non nuls renseignés, c'est-à-dire la même base que le traitement correct. La moyenne qui vaut 2 374 €, soit 236 € de moins, est celle de l'étudiant qui corrige le 999 999 mais **conserve** les 675 zéros.

10. La valeur 1 859,27 apparaît trois fois. Est-ce un code de non-réponse ?

▶ **Non : trois salariés peuvent gagner le même montant**

Un code de non-réponse est une valeur ronde, aberrante, répétée des centaines de fois, et déclarée dans le dictionnaire. 1 859,27 est un montant plausible avec des centimes : la répétition est une coïncidence ordinaire.

11. `ACTEU` est vide pour toutes les personnes de moins de 15 ans.

▶ **D'un hors champ : la question ne leur a pas été posée**

Le vide est ici parfaitement informatif : la variable n'a pas de sens avant 15 ans. Imputer reviendrait à inventer une activité à des enfants. Le hors champ se reconnaît à sa régularité : il suit exactement une règle de l'enquête.

12. Non-réponse au patrimoine : 3 % chez les non-diplômés, 11 % chez les diplômés du supérieur.

▶ **Elle dépend au moins d'une variable observée — reste à savoir si elle dépend aussi du patrimoine lui-même**

L'écart 3 / 11 établit que la non-réponse n'est pas complètement au hasard. Il établit MAR au minimum. Rien dans les données n'exclut qu'elle dépende en plus du patrimoine non déclaré, ce qui serait MNAR : la distinction ne se tranche pas depuis le fichier.

13. Dans cette situation, que peut-on faire ?

▶ **Rien : aucune correction n'est possible à partir des seules données observées — voir l'avertissement**

Cette réponse vaut si la non-réponse est MNAR. Dans la question précédente, telle qu'elle est rédigée, on sait seulement que la non-réponse dépend du diplôme : corriger en tenant compte des variables observées est alors la pratique courante, et cette option est au moins aussi défendable.

Pondération

14. Taux de chômage en comptant les lignes : 7,95 %. L'INSEE publie 7,4 %.

▶ **Compter les lignes décrit l'échantillon, pas la population**

Chaque personne interrogée représente un nombre variable d'habitants, inscrit dans la variable de poids (`EXTRIAN`). Sans elle, on décrit qui a répondu, pas la France. Le bon calcul est une moyenne pondérée.

15. Vous filtrez sur les 15-64 ans puis sommez `EXTRIAN` : 55,4 millions, soit exactement le total initial.

▶ **Le filtre n'a pas fonctionné**

Un sous-ensemble strict ne peut pas avoir le même poids total que l'ensemble. L'égalité exacte est la signature d'un filtre vide d'effet — type incompatible, condition écrite sur la mauvaise colonne, résultat non réaffecté. C'est le contrôle qui rattrape l'erreur silencieuse.

Définitions et indices

16. 2,33 millions de chômeurs au sens du BIT, 5,85 millions d'inscrits à France Travail.

▶ **Les deux sont exacts et comptent des personnes différentes**

Les deux ensembles se recoupent sans s'emboîter : des chômeurs BIT ne sont pas inscrits, et beaucoup d'inscrits (catégories B et C) ont travaillé dans le mois, ce qui les exclut du chômage BIT. L'option « les inscrits incluent les chômeurs BIT » décrit une inclusion qui n'existe pas.

17. Pain $+12{,}5$ %, lait $+7{,}4$ %, café -5 %. Moyenne simple : 4,96 %. Panier réel : 7,46 %.

▶ **Les biens ne pèsent pas le même poids dans le budget**

Une moyenne simple suppose que les trois biens comptent autant. Un indice de prix est une moyenne *pondérée* par la part de chaque bien dans la dépense : le pain, plus acheté, tire l'indice vers le haut.

18. Le prix de l'électricité augmente fortement, les ménages en réduisent la consommation. Quel indice donne le chiffre le plus élevé ?

▶ **Laspeyres, car il garde les quantités d'avant la hausse**

Laspeyres facture aux prix d'aujourd'hui un panier que les ménages ont justement cessé d'acheter parce qu'il avait renchéri. Paasche, qui pondère par les quantités récentes, donne moins de poids à l'électricité. L'écart entre les deux *mesure* la substitution.

Dossier documentaire

Rappel du dossier projeté. Dix lignes, six variables. `IDENT` apparaît deux fois pour 01053 et deux fois pour 07186. Non-réponses déclarées : `AGE` = 99, `SALAIRE_NET` = 999 999, `TEMPS` = 9. Les salaires supérieurs à 10 000 € sont ramenés à 10 000 (plafond de diffusion).

19. Vrai ou faux : le fichier décrit dix personnes.

▶ **Faux**

Dix *lignes*, huit *personnes* : 01053 et 07186 occupent chacun deux postes dans l'année. Confondre les deux conduit à diviser une somme de salaires par le mauvais effectif.

20. Vrai ou faux : une fois les quatre valeurs manquantes converties, `isna()` en signalera quatre.

▶ **Vrai**

Après conversion seulement. Avant, `isna()` renvoie zéro : les absences sont codées en nombres — 999 999, 99, 9 — que Python lit comme des valeurs valides. Elles ne deviennent manquantes qu'après un `replace` explicite.

21. Vrai ou faux : le code 9 de `TEMPS` est une non-réponse.

▶ **Vrai**

Le dictionnaire le déclare : 1 complet, 2 partiel, 9 non-réponse. À remplacer par `NaN` avant tout comptage, sans quoi « 9 » apparaîtra comme un troisième temps de travail.

22. Vrai ou faux : la clé de ce fichier est `IDENT`.

▶ **Faux**

Une clé ne prend jamais deux fois la même valeur ; `IDENT` se répète. La clé est le couple `IDENT` + `NOPOSTE`. C'est aussi la colonne sur laquelle s'appuierait une fusion : la supposer unique produit des doublons silencieux.

23. Vrai ou faux : l'écart de salaire entre les deux salariés à 10 000 € est nul.

▶ **Faux**

10 000 est un **plafond de diffusion** : tous les salaires supérieurs y sont ramenés. On sait seulement que ces deux salariés gagnent *au moins* 10 000 €. L'écart réel est inconnu, et toute moyenne calculée sur cette colonne est une borne inférieure.

24. Vrai ou faux : un salaire de 0 € est nécessairement une erreur de saisie.

▶ **Faux**

Le zéro code ici « sans objet » : la personne n'est pas salariée. C'est une situation réelle, pas une erreur. Elle doit sortir du champ quand on étudie les salaires, mais pas être corrigée.

25. Vrai ou faux : `REGION` peut être chargée comme un nombre sans risque.

▶ **Faux**

Le dictionnaire la déclare de type caractère. Un code de région ne s'additionne pas et ne se compare pas ; chargé en nombre, il perd ses zéros initiaux, ce qui fait échouer toute fusion ultérieure avec un fichier où ils sont conservés.

26. Vrai ou faux : la moyenne d'âge calculée directement sur ce tableau est fausse.

▶ **Vrai**

Deux raisons se cumulent. Le code 99 est une non-réponse, et il entre dans la moyenne comme un âge. Et les deux salariés à deux postes sont comptés deux fois : la moyenne porte sur des lignes, non sur des personnes.

27. Combien de personnes distinctes ?

▶ **8**

Dix lignes, mais `01053` et `07186` y figurent deux fois chacun. `df["IDENT"].nunique()` donne la réponse ; `len(df)` donne le nombre de postes.

28. Combien de valeurs sont réellement manquantes ?

▶ **4**

Deux salaires à 999 999, un âge à 99, un temps de travail à 9. Aucune case n'est vide à l'écran : ce sont quatre codes, repérables uniquement par le dictionnaire.

29. Quel salaire moyen obtient-on sans rien corriger ?

▶ **202 904 €**

Les deux codes 999 999 pèsent deux millions d'euros à eux seuls, sur dix lignes. Le résultat n'est pas « un peu faux » : il est aberrant, et c'est précisément ce qui le rend facile à repérer. Les erreurs dangereuses sont celles qui restent plausibles.

30. Après avoir mis 999 999 en manquant et écarté le salaire nul, sur combien de salaires porte la moyenne ?

▶ **7**

Dix lignes, moins les deux non-réponses, moins la ligne à 0 € qui sort du champ des salariés. Le dénominateur d'une moyenne se compte : il ne se devine pas.

31. Quelle est la médiane de ces sept salaires ?

▶ **2 145,60 €**

Rangés : 412,30 — 1 502,15 — 1 876,45 — **2 145,60** — 3 104,80 — 10 000 — 10 000. La valeur centrale est la quatrième. La moyenne, elle, vaut 4 148,76 € : les deux plafonds la tirent vers le haut, pas la médiane.

32. Parmi les lignes où `TEMPS` est renseigné, quelle part est à temps partiel ?

▶ **33 %**

Neuf lignes renseignées (la dixième porte le code 9), dont trois à temps partiel : $3/9 = 33$ %. Mettre le 9 au dénominateur donnerait 30 % — l'erreur classique, qui consiste à compter une non-réponse comme une modalité.

33. Vous imputez les trois salaires manquants par la moyenne des sept autres.

▶ **La même moyenne, un écart-type plus faible**

Imputer par la moyenne ajoute des points exactement au centre : la moyenne ne bouge pas, mais la dispersion diminue mécaniquement. On fabrique ainsi une précision qui n'existe pas — et avec elle, des intervalles de confiance trop étroits.

Contrôles, nettoyage, interprétation

34. Fusion de 34 904 communes avec 100 départements en `how="left"` : 34 910 lignes en sortie.

▶ **Un code département figure plusieurs fois dans la table de droite**

`how="left"` garde toutes les lignes de gauche, mais *duplique* celles qui trouvent plusieurs correspondances à droite. Six lignes de trop = six appariements multiples. Le garde-fou est `validate="m:1"`, qui lève une erreur au lieu de gonfler le tableau.

35. Taux de chômage : 7,95 % sans les poids, 7,44 % avec.

▶ **Les chômeurs sont sur-représentés dans l'échantillon interrogé**

Si la pondération fait baisser le taux, c'est que les chômeurs portent un poids moyen plus faible : ils sont plus nombreux dans l'échantillon que dans la population. La pondération corrige ce déséquilibre ; elle ne réduit pas l'incertitude, et ne rend pas l'échantillon inutilisable.

36. « Durée du travail » vide pour 30 % des lignes, toutes des chômeurs.

▶ **Vous les conservez, en restreignant tout calcul de durée aux personnes en emploi**

Le vide est un hors champ : un chômeur n'a pas de durée du travail. Supprimer les lignes ferait disparaître les chômeurs de toutes les autres analyses ; imputer ou coder à zéro inventerait une information. On restreint le *calcul*, pas le fichier.

37. La règle des 1,5 écarts signale 717 observations avant nettoyage, 269 après avoir mis 999 999 en manquant.

▶ **Les codes gonflaient le troisième quartile, donc le seuil, et se signalaient eux-mêmes**

Les 525 codes étaient à la fois *dans* le calcul du seuil et *parmi* les points signalés. Les retirer fait tomber le seuil de 6 038 à 5 406 € : un seuil plus bas, et pourtant moins de points. Toute statistique calculée avant nettoyage est contaminée par ce qu'elle est censée détecter.

38. Écart de salaire hommes-femmes : 336 € sur l'ensemble, 146 € parmi les seuls temps complets.

▶ **Environ 57 % de l'écart brut tient à la différence de temps de travail**

$(336 - 146)/336 \simeq 57$ %. Le reste subsiste à temps de travail identique : le temps partiel n'explique donc pas tout. Et « à temps complet » n'est pas « à travail égal » — le poste, le secteur et l'ancienneté n'ont pas été tenus constants.

39. « Un jeune sur cinq au chômage » : taux de chômage des 15-24 ans 18,8 %, taux d'activité 40 %.

▶ **Environ 7,5 %**

Le taux de chômage a pour dénominateur les *actifs*, pas la classe d'âge : $18{,}8 \times 0{,}40 \simeq 7{,}5$ %. La plupart des 15-24 ans sont en études, donc inactifs. L'erreur est d'autant plus fréquente que le chiffre juste reste préoccupant.