Wooclap — partie 3, corrigé commenté

Analyse des données — L3 Économie — banque de 27 questions

Dossier documentaire

Rappel du dossier projeté. Dix lignes, six variables. `IDENT` apparaît deux fois pour 01053 et deux fois pour 07186. Non-réponses déclarées : `AGE` = 99, `SALAIRE_NET` = 999 999, `TEMPS` = 9. Les salaires supérieurs à 10 000 € sont ramenés à 10 000 (plafond de diffusion).

1. Vrai ou faux : `REGION` peut être chargée comme un nombre sans risque.

▶ **Faux**

Le dictionnaire la déclare de type caractère. Un code de région ne s'additionne pas et ne se compare pas ; chargé en nombre, il perd ses zéros initiaux, ce qui fait échouer toute fusion ultérieure avec un fichier où ils sont conservés.

2. Vrai ou faux : la moyenne d'âge calculée directement sur ce tableau est fausse.

▶ **Vrai**

Deux raisons se cumulent. Le code 99 est une non-réponse, et il entre dans la moyenne comme un âge. Et les deux salariés à deux postes sont comptés deux fois : la moyenne porte sur des lignes, non sur des personnes.

3. Combien de personnes distinctes ?

▶ **8**

Dix lignes, mais `01053` et `07186` y figurent deux fois chacun. `df["IDENT"].nunique()` donne la réponse ; `len(df)` donne le nombre de postes.

4. Combien de valeurs sont réellement manquantes ?

▶ **4**

Deux salaires à 999 999, un âge à 99, un temps de travail à 9. Aucune case n'est vide à l'écran : ce sont quatre codes, repérables uniquement par le dictionnaire.

5. Quel salaire moyen obtient-on sans rien corriger ?

▶ **202 904 €**

Les deux codes 999 999 pèsent deux millions d'euros à eux seuls, sur dix lignes. Le résultat n'est pas « un peu faux » : il est aberrant, et c'est précisément ce qui le rend facile à repérer. Les erreurs dangereuses sont celles qui restent plausibles.

6. Après avoir mis 999 999 en manquant et écarté le salaire nul, sur combien de salaires porte la moyenne ?

▶ **7**

Dix lignes, moins les deux non-réponses, moins la ligne à 0 € qui sort du champ des salariés. Le dénominateur d'une moyenne se compte : il ne se devine pas.

7. Quelle est la médiane de ces sept salaires ?

▶ **2 145,60 €**

Rangés : 412,30 — 1 502,15 — 1 876,45 — **2 145,60** — 3 104,80 — 10 000 — 10 000. La valeur centrale est la quatrième. La moyenne, elle, vaut 4 148,76 € : les deux plafonds la tirent vers le haut, pas la médiane.

8. Parmi les lignes où `TEMPS` est renseigné, quelle part est à temps partiel ?

▶ **33 %**

Neuf lignes renseignées (la dixième porte le code 9), dont trois à temps partiel : $3/9 = 33$ %. Mettre le 9 au dénominateur donnerait 30 % — l'erreur classique, qui consiste à compter une non-réponse comme une modalité.

9. Vous imputez les trois salaires manquants par la moyenne des sept autres.

▶ **La même moyenne, un écart-type plus faible**

Imputer par la moyenne ajoute des points exactement au centre : la moyenne ne bouge pas, mais la dispersion diminue mécaniquement. On fabrique ainsi une précision qui n'existe pas — et avec elle, des intervalles de confiance trop étroits.

Contrôles et interprétation

10. Fusion de 34 904 communes avec 100 départements en `how="left"` : 34 910 lignes en sortie.

▶ **Un code département figure plusieurs fois dans la table de droite**

`how="left"` garde toutes les lignes de gauche, mais *duplique* celles qui trouvent plusieurs correspondances à droite. Six lignes de trop = six appariements multiples. Le garde-fou est `validate="m:1"`, qui lève une erreur au lieu de gonfler le tableau.

11. Taux de chômage : 7,95 % sans les poids, 7,44 % avec.

▶ **Les chômeurs sont sur-représentés dans l'échantillon interrogé**

Si la pondération fait baisser le taux, c'est que les chômeurs portent un poids moyen plus faible : ils sont plus nombreux dans l'échantillon que dans la population. La pondération corrige ce déséquilibre ; elle ne réduit pas l'incertitude, et ne rend pas l'échantillon inutilisable.

12. « Durée du travail » vide pour 30 % des lignes, toutes des chômeurs.

▶ **Vous les conservez, en restreignant tout calcul de durée aux personnes en emploi**

Le vide est un hors champ : un chômeur n'a pas de durée du travail. Supprimer les lignes ferait disparaître les chômeurs de toutes les autres analyses ; imputer ou coder à zéro inventerait une information. On restreint le *calcul*, pas le fichier.

13. La règle des 1,5 écarts signale 717 observations avant nettoyage, 269 après avoir mis 999 999 en manquant.

▶ **Les codes gonflaient le troisième quartile, donc le seuil, et se signalaient eux-mêmes**

Les 525 codes étaient à la fois *dans* le calcul du seuil et *parmi* les points signalés. Les retirer fait tomber le seuil de 6 038 à 5 406 € : un seuil plus bas, et pourtant moins de points. Toute statistique calculée avant nettoyage est contaminée par ce qu'elle est censée détecter.

14. Écart de salaire hommes-femmes : 336 € sur l'ensemble, 146 € parmi les seuls temps complets.

▶ **Environ 57 % de l'écart brut tient à la différence de temps de travail**

$(336 - 146)/336 \simeq 57$ %. Le reste subsiste à temps de travail identique : le temps partiel n'explique donc pas tout. Et « à temps complet » n'est pas « à travail égal » — le poste, le secteur et l'ancienneté n'ont pas été tenus constants.

15. « Un jeune sur cinq au chômage » : taux de chômage des 15-24 ans 18,8 %, taux d'activité 40 %.

▶ **Environ 7,5 %**

Le taux de chômage a pour dénominateur les *actifs*, pas la classe d'âge : $18{,}8 \times 0{,}40 \simeq 7{,}5$ %. La plupart des 15-24 ans sont en études, donc inactifs. L'erreur est d'autant plus fréquente que le chiffre juste reste préoccupant.

Fonctions, imputation, journal de nettoyage

16. `def retirer(serie, code): return serie.replace(code, np.nan)` — pourquoi `code` en argument ?

▶ **Parce que le code de non-réponse n'est pas le même d'une variable à l'autre**

999 999 pour le salaire, 99 pour l'âge, 9 pour le temps de travail. Écrire la valeur dans la fonction obligerait à en réécrire une par variable. Un argument est ce qui change d'un appel à l'autre.

17. Vous imputez les 525 salaires manquants par la moyenne. La corrélation salaire-diplôme valait 0,303.

▶ **Elle baisse à 0,292**

Les points imputés portent tous la même valeur de salaire, quel que soit leur diplôme : ce sont 525 observations sans lien, ajoutées à un nuage qui en avait un. La moyenne est préservée, la relation diluée. C'est le coût caché

de l'imputation par la moyenne.

18. `PRIME` est vide pour 60 % des lignes.

▶ **Vous gardez le vide tel quel : il signifie « n'a pas touché de prime »**

C'est un zéro structurel, non une absence d'information : imputer la prime moyenne attribuerait une prime à ceux qui n'en ont pas. Attention toutefois : dans ce fichier, la colonne contient *aussi* 336 lignes codées 999 999. Un vide et un code de non-réponse peuvent coexister dans la même variable.

19. Qu'affiche ce `print` ?

```
df[df["SALAIRE_NET"] == 999999]["SALAIRE_NET"] = np.nan
print(df["SALAIRE_NET"].isna().sum())
```

▶ **0**

L'affectation porte sur un extrait temporaire, aussitôt jeté : `df` n'a pas changé, et aucune valeur n'est devenue manquante. Aucune erreur n'interrompt l'exécution — c'est ce qui rend l'écriture dangereuse. La forme correcte : `df["SALAIRE_NET"] = df["SALAIRE_NET"].replace(999999, np.nan)`.

20. Dans le journal, une étape fait passer la moyenne de 67 745 à 2 374 €, une autre de 2 374 à 2 610 €.

▶ **Elle a changé la définition de l'indicateur, pas seulement sa valeur**

La première corrige une aberration : 67 745 € n'était le salaire de personne. La seconde écarte les non-salariés : on ne mesure plus « le salaire moyen des lignes du fichier » mais « le salaire moyen des salariés ». Deux grandeurs différentes, toutes deux justes — à condition de dire laquelle on publie.

21. Parmi les trois traitements des valeurs manquantes, lequel ne suppose rien sur ce qu'on ne voit pas ?

▶ **Conserver et signaler**

Supprimer suppose que les lignes incomplètes ressemblent aux autres ; imputer par la moyenne suppose que les absents valent la moyenne des présents. Conserver et signaler ne suppose rien, mais oblige à publier le taux de non-réponse — ce qui est précisément le point.

Points anormaux

22. Un point dont le X est ordinaire mais dont le Y s'écarte nettement de la tendance.

▶ **D'un point atypique**

Deux critères à croiser : *éloignement* en X (valeur extrême) et *écart au modèle* en Y (point atypique). Ici le X est banal, donc le levier est faible : le point se voit, mais déplace peu la droite.

23. Une observation ajoutée à un nuage de 24 points fait passer la pente de 42 à 7.

▶ **D'un point influent**

Est influent le point dont le retrait change la conclusion. Cela suppose en général un X éloigné : le bras de levier est long. Le diagnostic ne se fait pas à l'œil mais par comparaison — avec et sans le point.

24. Seuil de 6 038 € et 717 points signalés avant nettoyage ; 5 406 € et 269 points après. Contradictoire ?

▶ **Non : on a retiré 525 observations qui étaient elles-mêmes signalées**

Un seuil plus bas signalerait davantage de points *à distribution inchangée*. Or elle a changé : les 525 codes ont disparu de la série, et ils comptaient parmi les 717. Vérifier avant d'invoquer une erreur de calcul.

25. Sur le fichier nettoyé, la règle signale 269 salaires, dont le plus faible vaut 5 407 €.

▶ **Les garder : ils appartiennent à la population étudiée**

5 407 € est un salaire parfaitement ordinaire. La règle des 1,5 écarts *signale*, elle ne juge pas : sur une distribution asymétrique, elle désigne mécaniquement la queue haute. Retirer ces points reviendrait à supprimer les cadres pour obtenir une distribution plus régulière.

26. Retirer les 269 salaires signalés fait passer la moyenne de 2 610 à 2 406 €.

▶ **Que les retirer coûte 8 % sur un indicateur simple, et bien plus sur un indicateur d'inégalité**

$204/2\,610 \simeq 8$ % : l'effet sur la moyenne est modéré. Mais ces 269 points sont toute la queue haute : un indice d'inégalité calculé sans eux n'a plus de sens. Le test du « avec et sans » ne dit pas s'il faut retirer ; il dit ce que retirer coûterait, et sur quel indicateur.

27. 72 salaires valent exactement 10 000 €, plafond de diffusion. Conséquence pour un indice d'inégalité ?

► **Il est sous-estimé**

Les hauts salaires sont tous ramenés à la même valeur : la queue de distribution est écrasée, donc la dispersion mesurée est inférieure à la dispersion réelle. Le Gini obtenu est une **borne inférieure**, à présenter comme telle.