

TD 3 — Nettoyer un vrai fichier

Analyse des données — L3 Économie — CY Cergy Paris Université

La question de la séance. Le salaire moyen de `cm03-salaires.csv` vaut **67 745 euros par mois**. Personne ne l’a mal calculé.

Trouvez pourquoi, et dites ce qu’il vaut réellement. Vous le ferez en quatorze questions et une demi-douzaine de décisions, dont chacune devra être écrite et chiffrée.

Le livrable n’est pas un fichier propre. C’est le **journal des décisions**, avec l’effet de chacune sur le résultat.

Ce dont vous avez besoin. Le notebook `td03-nettoyage.ipynb`, le fichier `cm03-salaires.csv` vu en séance 3, et son **dictionnaire des variables**. Ouvrez le dictionnaire dans un onglet à côté : aucune question de ce TD ne se répond sans lui.

1. Le journal, ouvert dès le départ

Un journal rempli de mémoire à la fin de la séance est faux. On ne se souvient ni de l’ordre des décisions, ni des effectifs intermédiaires. Celui-ci s’ouvre avant la première décision et se remplit tout seul.

Question 1. Notez le salaire moyen initial et le nombre de lignes. Ce sont vos points de comparaison pour tout le reste du TD. Pourquoi ouvrir le journal maintenant plutôt qu’à la fin ?

Retirez ensuite les lignes strictement identiques à une autre, et notez la décision. Le fichier perd quelques lignes et la moyenne ne bouge presque pas : l’étape était nécessaire, son effet est négligeable, et le journal permet de constater les deux.

2. Les manquants qui n’en ont pas l’air

`SALAIRE_NET` n’affiche aucun manquant, et trois de ses valeurs reviennent des centaines de fois. Six colonnes du fichier codent leur non-réponse par un nombre.

Avant de coder, remplissez ce tableau à partir du dictionnaire.

Colonne	Non-réponse	Sans objet	Censure
<code>SALAIRE_NET</code>			
<code>PRIME</code>			
<code>HEURES</code>			
<code>DIPLOME</code>			
<code>TEMPS</code>			
<code>CONTRAT</code>			
<code>MOTIF_ABS</code>			
<code>ANCIENNETE</code>			

Question 2. Écrivez une fonction de nettoyage et appliquez-la aux six colonnes concernées. De combien le salaire moyen a-t-il bougé ? Donnez l’écart en euros et en facteur multiplicatif. Aucun message d’erreur n’est apparu, ni avant ni après : qu’en reprenez-vous ?

Question 3. Une colonne ne suit pas la même règle que les autres. Sur `MOTIF_ABS`, quel code est la non-réponse, et que signifie le code 9 ? Combien de situations un `replace` appliqué par habitude au code 9 détruirait-il ? La fonction est-elle en cause ?

Question 4. Croisez la non-réponse au salaire avec trois variables du fichier. Décrivez ce que montre chacun des trois croisements. Y a-t-il une variable qui explique la non-réponse, et deux qui n'expliquent rien ?

Question 5. De quel type est cette non-réponse : complètement au hasard, au hasard conditionnellement, ou non au hasard ? Justifiez.

- Qu'est-ce que les données vous permettent d'affirmer ?
- Qu'est-ce qu'elles ne vous permettent pas d'affirmer, et pourquoi ?
- Si vous supprimez ces lignes, la moyenne sera-t-elle sur-estimée ou sous-estimée ? Et les inégalités ?

3. Zéro n'est pas manquant

Question 6. Combien de salaires valent exactement zéro, et qui sont ces personnes ? Trois hypothèses sont plausibles a priori : non-salariés hors champ, non-réponse codée en zéro, ou personnes n'ayant pas travaillé sur la période. Laquelle est la bonne, et qu'est-ce qui vous permet de trancher ?

Question 7. Calculez la moyenne avec et sans ces lignes. De combien change-t-elle ? Quelle décision retenez-vous, et à quelle question répondez-vous en la retenant ? « Salaire moyen » et « revenu d'activité moyen » ne sont pas la même chose.

Une fois la décision appliquée, comptez les `ANCIENNETE` égales à -1 et regardez les modalités restantes de `CONTRAT`. Deux codes « sans objet » ont disparu d'eux-mêmes. Expliquez pourquoi : un champ bien défini nettoie plusieurs colonnes à la fois.

4. La censure haute

Question 8. Affichez les valeurs les plus fréquentes de `SALAIRE_NET`, puis ses quantiles à 90, 95, 99 et 99,9 %. Que remarquez-vous en comparant les deux derniers ? Que dit le dictionnaire sur cette valeur ? Cherchez le même mécanisme sur `HEURES`.

Question 9. Calculez un indice de Gini sur les salaires observés. Est-il sur-estimé ou sous-estimé ? Le sens de l'erreur est connu sans ambiguïté : dites lequel et pourquoi. Pouvez-vous dire *de combien* ? Justifiez.

Question 10. Écrivez, en une phrase, ce que vous feriez figurer dans la note méthodologique d'un mémoire qui utiliserait ce Gini. La phrase doit mentionner le plafond, la part des observations concernées, et la nature de la borne obtenue.

5. Les doublons

Question 11. Comptez les lignes identiques partout, les identifiants répétés, puis les couples `IDENT` + `NOPOSTE` répétés. Les deux premiers comptages ne mesurent pas la même chose : expliquez la différence, puis dites quelle est la **clé** de ce fichier.

- Sur quoi diffèrent les deux lignes d'un même `IDENT` ?
- Que perdriez-vous en supprimant les identifiants répétés ?
- Si votre question portait sur les **personnes** et non sur les postes, que faudrait-il faire à la place ?

6. Le journal, et le test de robustesse

Question 12. Commentez votre journal, ligne par ligne. Quelle étape était nécessaire et sans effet ? Quelle étape a changé le résultat d'un facteur ? La dernière ligne ne change pas la moyenne : qu'est-ce qu'elle change alors ?

Question 13. Refaites le calcul en imputant les salaires manquants au lieu de les écarter, et comparez moyenne, écart-type, indice de Gini et nombre d'observations.

- Laquelle des quatre lignes bouge le moins ? Pourquoi est-ce précisément ce qui rend l'imputation trompeuse ?
- Que devient la dispersion, et pourquoi ?
- Que devient le Gini ? Formulez ce que l'imputation fait à l'inégalité mesurée.
- Le nombre d'observations annoncé change. Quelle conséquence sur les erreurs-types d'une régression faite ensuite ?

Question 14. Le test de robustesse ne cherche pas la bonne réponse : il n'y en a pas. Identifiez **votre décision la plus discutable**, et dites si votre conclusion y survit. Distinguez la conclusion sur la moyenne et celle sur les inégalités : elles ne se comportent pas pareil.

Avant la séance 4. Terminez votre journal : une ligne par décision, avec sa justification. Vérifiez que le notebook s'exécute entièrement de haut en bas sans erreur. Reprenez enfin `MOTIF_ABS` et `CONTRAT` dans le dictionnaire, et écrivez pour chacune quels codes sont des non-réponses et lesquels sont du hors champ.

Ce travail n'est pas noté. En revanche, les questions de diagnostic du contrôle continu seront construites à partir des erreurs les plus fréquentes rencontrées ici.

Les données de ce TD sont fabriquées pour l'enseignement. Les ordres de grandeur sont plausibles, les valeurs ne sont celles d'aucune source réelle. Les difficultés, elles, sont celles d'un vrai fichier de diffusion.