

TD 3 — Le salaire moyen

Analyse des données — L3 Économie — CY Cergy Paris Université

stefaniamarcassa.github.io/analyse_des_donnees

Le point de départ. Le salaire moyen de `cm03-salaires.csv` vaut **67 745 euros par mois**. Personne ne l'a mal calculé.

Votre travail : trouver pourquoi, et dire ce qu'il vaut réellement.

Ouvrez le dictionnaire des variables dans un onglet à côté, comme au TD précédent. Aucune question ne se répond sans lui.

1. Le point de départ

Chargez le fichier ; les montants sont écrits en texte, convertissez-les en nombres. Puis **ouvrez un journal** : un tableau où vous noterez, après chaque correction, le nombre de lignes et le salaire moyen.

Question 1. Combien de lignes le fichier contient-il ? Quel est le salaire moyen avant toute correction ?

Question 2. Cherchez le salaire net mensuel moyen en France, publié par l'INSEE. Votre chiffre est combien de fois plus élevé ?

2. Trouver la cause

Question 3. Combien de valeurs manquantes `isna()` signale-t-il sur `SALAIRE_NET` ?

Question 4. Affichez les cinq valeurs les plus fréquentes de `SALAIRE_NET`. L'une d'elles revient 525 fois et ne peut pas être un salaire : laquelle ?

Question 5. Cherchez cette valeur dans le dictionnaire. Que signifie-t-elle ?

Question 6. Écrivez **une fonction** qui remplace cette valeur par une valeur manquante, et appliquez-la à `SALAIRE_NET` puis à `PRIME`. Quel est le nouveau salaire moyen ?

Question 7. Aucun message d'erreur n'est apparu, ni avant ni après la correction. Qu'en concluez-vous sur ce type de problème ?

3. Le piège

Question 8. Affichez la distribution de `MOTIF_ABS`. Deux codes ressemblent à des non-réponses : d'après le dictionnaire, lequel en est une, et que signifie l'autre ?

Question 9. Combien d'observations un `replace` appliqué au code 9 détruirait-il ? Votre fonction de la question 6 vous en protège-t-elle, et pourquoi ?

4. Zéro n'est pas manquant

Question 10. Combien de salaires valent exactement zéro ? Croisez-les avec `STATUT` et `CONTRAT` : qui sont ces personnes ?

Question 11. Calculez la moyenne avec et sans ces lignes. De combien change-t-elle ? Quelle décision retenez-vous — et à quelle question répondez-vous en la retenant ?

« Salaire moyen » et « revenu d'activité moyen » ne sont pas la même chose.

5. La censure haute

Question 12. Affichez les quantiles de `SALAIRE_NET` à 90, 95, 99 et 99,9 %. Que remarquez-vous en comparant les deux derniers ? Que dit le dictionnaire sur cette valeur ?

Question 13. Écrivez en une phrase ce que vous feriez figurer dans une note méthodologique : le plafond, la part des observations concernées, et ce que cela interdit d'affirmer.

Question 14. Relisez votre journal. Entre la première et la dernière ligne, de combien le salaire moyen a-t-il varié ? Une étape était nécessaire sans changer le résultat : laquelle, et qu'a-t-elle changé alors ?

6. Pour ceux qui ont terminé

Question 15. [facultatif] Comptez les lignes identiques partout, puis les `IDENT` répétés. Les deux comptages ne mesurent pas la même chose : expliquez la différence, et dites quelle est la **clé** de ce fichier.

Question 16. [facultatif] Refaites le calcul en imputant les salaires manquants par la moyenne au lieu de les écarter. Comparez moyenne et écart-type. Que s'est-il passé ?

Question 17. [facultatif] Identifiez votre décision la plus discutable et prenez la décision inverse. Votre conclusion y survit-elle ?

Avant la séance suivante. Vérifiez que le notebook s'exécute de haut en bas, journal compris. Conservez ce tableau : c'est ce qu'on attend dans la note méthodologique d'un mémoire.