

TD 3 — Le salaire moyen

Analyse des données — L3 Économie — CY Cergy Paris Université

stefaniamarcassa.github.io/analyse_des_donnees

Le point de départ. Le salaire moyen de `cm03-salaires.csv` vaut **67 745 euros par mois**. Personne ne l'a mal calculé.

Votre travail : trouver pourquoi, et dire ce qu'il vaut réellement. Chaque décision se note et se chiffre.

Ouvrez le dictionnaire des variables dans un onglet à côté, comme au TD précédent. Aucune question ne se répond sans lui.

1. Le journal, ouvert dès le départ

Avant toute correction, notez le nombre de lignes et le salaire moyen. Ce sont vos points de comparaison.

Question 1. Pourquoi ouvrir le journal maintenant plutôt qu'à la fin ?

2. Les manquants qui n'en ont pas l'air

Le fichier ne contient presque aucune valeur manquante au sens de `isna()`. Pourtant le salaire moyen est absurde.

Question 2. Affichez les valeurs les plus fréquentes de `SALAIRE_NET`. Que voyez-vous ? Écrivez **une fonction** qui convertit le code de non-réponse en valeur manquante, et appliquez-la aux colonnes concernées.

De combien le salaire moyen a-t-il bougé ? Donnez l'écart en euros **et** en facteur multiplicatif. Aucun message d'erreur n'est apparu, ni avant ni après : qu'en reprenez-vous ?

Question 3. Une colonne ne suit pas la même règle. Sur `MOTIF_ABS`, quel code est la non-réponse, et que signifie le code 9 ? Combien d'observations un `replace` appliqué par habitude au code 9 détruirait-il ?

3. Zéro n'est pas manquant

Question 4. Combien de salaires valent exactement zéro ? Croisez-les avec `STATUT` et `CONTRAT` : qui sont ces personnes ?

Question 5. Calculez la moyenne avec et sans ces lignes. De combien change-t-elle ? Quelle décision reprenez-vous — et à quelle question répondez-vous en la retenant ?

« Salaire moyen » et « revenu d'activité moyen » ne sont pas la même chose.

4. La censure haute

Question 6. Affichez les quantiles de `SALAIRE_NET` à 90, 95, 99 et 99,9 %. Que remarquez-vous en comparant les deux derniers ? Que dit le dictionnaire sur cette valeur ?

Question 7. Écrivez en une phrase ce que vous feriez figurer dans une note méthodologique. La phrase doit mentionner le plafond, la part des observations concernées, et ce que cela interdit d'affirmer.

5. Le journal

Question 8. Relisez votre journal. Entre la première et la dernière ligne, de combien le salaire moyen a-t-il varié ? Quelle étape était nécessaire mais sans effet sur le résultat — et qu'a-t-elle changé alors ?

6. Pour ceux qui ont terminé

Question 9. [facultatif] Comptez les lignes identiques partout, puis les `IDENT` répétés. Les deux comptages ne mesurent pas la même chose : expliquez la différence, et dites quelle est la **clé** de ce fichier.

Question 10. [facultatif] Refaites le calcul en imputant les salaires manquants par la moyenne au lieu de les écarter. Comparez moyenne et écart-type. Que s'est-il passé ?

Question 11. [facultatif] Identifiez votre décision la plus discutable et prenez la décision inverse. Votre conclusion y survit-elle ?

Avant la séance suivante. Vérifiez que le notebook s'exécute de haut en bas, journal compris. Conservez-le : ce tableau est exactement ce qu'on attend dans la note méthodologique d'un mémoire.