

TD 4 — Communes et départements

Analyse des données — L3 Économie — CY Cergy Paris Université

stefaniamarcassa.github.io/analyse_des_donnees

Les données. Les **populations de référence 2023** de l'INSEE : un classeur Excel qui donne la population de chaque commune, de chaque département, de chaque région. Page du fichier : www.insee.fr/fr/statistiques/8680726.

La question. Quelle part de la population de son département chaque commune représente-t-elle ? Pour la calculer, il faut **rapprocher deux tableaux** — c'est l'objet de ce TD.

Fusionner deux tableaux. `pd.merge` associe les lignes de deux tableaux qui partagent une **clé** .

```
f = gauche.merge(droite, on="cle", how="left", indicator=True)
```

`how="left"` garde toutes les lignes de gauche, qu'elles trouvent un partenaire ou non. `indicator=True` ajoute une colonne `_merge` qui dit, pour chaque ligne, si elle s'est appariée (`both`) ou non (`left_only`). **Comptez toujours les lignes avant et après.**

1. Charger

Les deux feuilles s'appellent `Communes` et `Départements`. Ouvrez d'abord le fichier dans un tableur pour voir à quoi il ressemble.

Question 1. Chargez les deux feuilles avec `header=7`. Pourquoi faut-il ce paramètre ?

Question 2. Combien de lignes contient chaque feuille ? De quoi une ligne est-elle la description, dans l'une et dans l'autre ?

2. La clé

Question 3. Quel est le type de `Code département` ? Et de `Code commune` ? Que vaut le code commune de L'Abergement-Clémenciat ?

Question 4. L'INSEE identifie une commune par le code département suivi d'un code commune **sur trois chiffres**. Construisez cet identifiant dans une colonne `CODGEO`. Vérifiez : L'Abergement-Clémenciat doit valoir 01001.

Question 5. Tous vos `CODGEO` font-ils cinq caractères ? Comptez-les par longueur. Lesquels font exception, et pourquoi ?

3. Fusionner

Question 6. Fusionnez les communes avec les départements, sur `Code département`, avec `how="left"` et `indicator=True`. Combien de lignes avant, combien après ? Pourquoi est-ce le même nombre ?

Question 7. Combien de communes ne trouvent pas leur département ? Lesquelles ?

Question 8. Cherchez ce que désignent leurs codes. Pourquoi ces communes n'ont-elles pas de département ?

4. Interpréter

Question 9. Calculez la part de chaque commune dans la population municipale de son département. Quelle commune pèse le plus lourd ? Le résultat vous surprend-il ?

Question 10. Ni Paris, ni Marseille, ni Lyon n'apparaissent en tête. Cherchez-les : pourquoi ?

5. Pour ceux qui ont terminé

Question 11. [facultatif] Cherchez « Marseille » avec `str.contains`. Qu'obtenez-vous, en plus des arrondissements ? Que conclure sur la recherche par nom ?

Question 12. [facultatif] Ajoutez `validate="m:1"` à votre fusion. Que vérifie ce paramètre ? Que se passerait-il si la feuille des départements contenait deux fois le même code ?

Question 13. [facultatif] Corrigez la construction de `CODGEO` pour l'outre-mer, et vérifiez que tous les codes font désormais cinq caractères.

Avant la séance suivante. Vérifiez que le notebook s'exécute de haut en bas. Retenez les trois contrôles de toute fusion : compter les lignes avant et après, lire la colonne `_merge`, et regarder les lignes qui ne se sont pas appariées.