TD 7 — L'équation de Mincer

Analyse des données — L3 Économie — CY Cergy Paris Université

stefaniamarcassa.github.io/analyse_des_donnees

Les données sont le fichier de salaires de la séance 3, déjà connu : `cm03-salaires.csv`. Vous commencerez par le nettoyer comme vous avez appris à le faire.

La question. Combien rapporte une année d'études supplémentaire ? La régression qui y répond, posée par Jacob Mincer en 1974, est la plus estimée de toute l'économie appliquée. Vous l'estimerez, et vous apprendrez surtout à **dire en une phrase** ce que signifie chaque coefficient.

1. Préparer les variables

Question 1. Chargez le fichier et appliquez le nettoyage de la séance 3 : le code `999 999` du salaire, les salaires nuls, le code `9` de `DIPLOME` et celui de `TEMPS`. Combien de lignes reste-t-il ?

Question 2. Créez `LSAL`, le logarithme du salaire. Pourquoi régresse-t-on le *logarithme* du salaire plutôt que le salaire lui-même ? Donnez deux raisons, l'une sur la forme de la distribution, l'autre sur la lecture des coefficients.

Question 3. Traduisez `DIPLOME` en **années d'études** à l'aide de la table ci-dessous. Cette traduction est une hypothèse, pas une simple conversion : laquelle ?

`DIPLOME`	1	2	3	4	5	6	7
	aucun	BEPC	CAP-BEP	bac	bac+2	bac+3/4	bac+5
années	**7**	**9**	**11**	**12**	**14**	**15**	**17**

Question 4. Construisez l'**expérience potentielle** : âge $-$ années d'études $-\,6$. Combien d'observations obtiennent une valeur *négative* ? Que faites-vous de ces lignes, et que coûte votre décision ?

Question 5. Créez la muette `FEMME`, qui vaut 1 pour les femmes et 0 pour les hommes. Pourquoi une seule colonne suffit-elle à coder deux sexes ?

2. Une différence de moyennes est une régression

Question 6. Calculez la moyenne de `LSAL` chez les hommes, puis chez les femmes, et leur différence.

Question 7. Estimez `LSAL ~ FEMME` avec `statsmodels`. Comparez la constante et le coefficient aux deux nombres de la question 6. Que constatez-vous, et pourquoi n'est-ce pas une coïncidence ?

Question 8. Refaites le test de Welch de la séance 5 sur les deux groupes. Comparez son t au t robuste du coefficient. Qu'en concluez-vous sur ce que fait réellement une régression sur une muette ?

3. L'équation de Mincer

Question 9. Estimez `LSAL ~ ETUDE`, puis ajoutez `EXPER` et son carré. Le rendement de l'éducation change-t-il ? Dans quel sens, et pourquoi fallait-il s'y attendre ?

Question 10. Le coefficient du carré de l'expérience est négatif. Que décrit-il ? À combien d'années d'expérience le profil de salaire atteint-il son sommet ?

Question 11. Ajoutez `FEMME`. Écrivez **une phrase par coefficient** — constante comprise — comme vous l'écririez sous un tableau d'article. Traduisez celui de `FEMME` en pourcentage du salaire.

4. L'interaction

Question 12. Ajoutez le terme `ETUDE:FEMME`. Quelle hypothèse ce coefficient teste-t-il ? Est-il significatif ? Et surtout : que signifie désormais le coefficient de `FEMME` seul ?

Question 13. Ajoutez le temps de travail. Que devient l'écart entre femmes et hommes ? Rapprochez ce résultat des 336 € et 146 € de la séance 5 : les deux disent-ils la même chose ?

5. Les écarts-types

Question 14. Réestimez avec `cov_type="HC1"`. Les coefficients bougent-ils ? Les écarts-types ? Refaites la comparaison sur le salaire *en niveau* plutôt qu'en logarithme, et expliquez l'écart entre les deux cas.

Question 15. De tous les modèles estimés, lequel publieriez-vous ? Justifiez en deux phrases, et dites ce que votre coefficient d'éducation ne mesure pas.

6. Pour ceux qui ont terminé

Question 16. [facultatif] Remplacez les années d'études par les six muettes de diplôme (`C(DIPLOME)`). Les écarts entre niveaux sont-ils réguliers ? Qu'est-ce que cela dit de l'hypothèse de la question 3 ?

Question 17. [facultatif] Estimez l'équation séparément sur les hommes et sur les femmes. Retrouvez-vous l'interaction de la question 12 ? Exactement ou approximativement, et pourquoi ?

Question 18. [facultatif] Votre R^2 plafonne autour de 0,22. Citez trois déterminants du salaire absents du fichier, et dites pour chacun s'il biaiserait le rendement de l'éducation vers le haut ou vers le bas.

Avant la séance suivante. Gardez votre notebook : la séance 8 repart de ce modèle. Et retenez la phrase à ne jamais écrire : « une année d'études *cause* 7 % de salaire en plus ». Vous verrez pourquoi.