TD 8 — Prix de l'immobilier et effets fixes

Analyse des données — L3 Économie — CY Cergy Paris Université

stefaniamarcassa.github.io/analyse_des_donnees

Les données sont les **DVF** — « Demandes de valeurs foncières », publiées par la direction générale des Finances publiques. Elles recensent *toutes* les ventes immobilières de France, avec leur prix. Vous travaillerez sur trois départements : le **Val-d'Oise**, les **Yvelines** et l'**Oise**. Chargement direct depuis l'URL, aucun fichier à télécharger.

La question. Combien vaut un mètre carré ? La réponse dépend massivement de l'endroit. Vous allez estimer une **régression hédonique** — le prix expliqué par les caractéristiques du bien — puis y ajouter des **effets fixes** géographiques, et regarder les coefficients se déplacer.

1. Ce que décrit une ligne

Question 1. Chargez les trois départements et empilez-les. Combien de **lignes** le fichier compte-t-il, et combien de **mutations distinctes** (`id_mutation`) ? Que vous apprend l'écart entre les deux nombres ?

Question 2. Affichez toutes les lignes d'une mutation qui en compte plusieurs. Que vaut `valeur_fonciere` sur chacune d'elles ? Qu'est-ce qu'une ligne décrit, exactement ?

Question 3. Sommez `valeur_fonciere` sur tout le fichier, puis sur les mutations dédoublonnées. De combien le premier chiffre se trompe-t-il ? Un article de presse fondé sur le premier serait-il faux, ou seulement imprécis ?

Question 4. Construisez le fichier d'analyse : **une ligne = un logement vendu seul**. Gardez les ventes d'un appartement ou d'une maison, et seulement les mutations qui ne contiennent *qu'un* logement. Dites, à chaque étape, combien de lignes vous perdez.

2. La régression hédonique

Question 5. Calculez le prix au mètre carré et regardez ses valeurs extrêmes. Fixez des bornes, justifiez-les, et dites combien d'observations elles écartent. Qu'est-ce qu'une vente à 1 € ?

Question 6. Estimez $\log(\text{prix}) \sim \log(\text{surface})$. Ce coefficient est une **élasticité** : énoncez-la en une phrase. Pourquoi ne vaut-elle pas 1 ?

Question 7. Ajoutez le nombre de pièces et une muette `maison`. Le coefficient de la surface bouge-t-il ? Comment se lit celui du nombre de pièces, maintenant qu'il est *à surface donnée* ?

3. Les effets fixes

Question 8. Ajoutez `C(code_departement)`. Combien de muettes cela crée-t-il ? Qu'est-ce que ces muettes absorbent, et que devient le R^2 ?

Question 9. Remplacez-les par `C(code_commune)`. Comparez les quatre modèles sur trois chiffres : le R^2, le coefficient de la surface, et celui de `maison`. Lequel des trois bouge le plus ?

Question 10. Le coefficient de `maison` s'est déplacé. Calculez la corrélation, entre communes, de la part de maisons et du prix moyen au mètre carré. Expliquez le mécanisme en deux phrases.

Question 11. Avec les effets fixes communaux, certaines variables deviennent **impossibles** à estimer. Donnez-en deux exemples qui vous intéresseraient en économie urbaine, et dites pourquoi elles disparaissent.

Question 12. Les effets fixes communaux n'absorbent pas tout. Citez deux déterminants du prix qui varient *à l'intérieur* d'une commune. Puis dites lequel des quatre modèles vous publieriez, et ce que son coefficient de surface ne mesure pas.

4. Pour ceux qui ont terminé

Question 13. [facultatif] Réestimez le dernier modèle avec des écarts-types **groupés par commune** (`cov_type="cluster"`). Lesquels augmentent, lesquels ne bougent pas ? Qu'est-ce que cela dit de la nature du bruit ?

Question 14. [facultatif] Récupérez les effets fixes communaux estimés et classez les communes. Le classement vous paraît-il plausible ? Quelle commune arrive en tête dans le Val-d'Oise ?

Question 15. [facultatif] Ajoutez des effets fixes **commune** $\times$ **trimestre**. Qu'absorbent-ils de plus que les effets fixes communaux seuls, et que coûte ce raffinement ?

Avant la séance suivante. Retenez la phrase du TD : un effet fixe ne *corrige* rien, il **absorbe**. Tout ce qui est constant dans le groupe disparaît — le biais que vous craigniez, mais aussi la variable que vous vouliez mesurer.