TD 9 — Peut-on prévoir un cours de bourse ?

Analyse des données — L3 Économie — CY Cergy Paris Université

stefaniamarcassa.github.io/analyse_des_donnees

Les données sont les cours de clôture quotidiens d'une valeur du CAC 40 et de l'indice, téléchargés depuis le notebook. Aucun fichier à récupérer.

La question. Jusqu'ici vous avez cherché à *expliquer*. Aujourd'hui vous allez *prévoir*, et ce n'est pas le même exercice : on ne juge plus un modèle sur son R^2, mais sur ce qu'il fait face à des données **qu'il n'a jamais vues**. Vous verrez que le premier modèle, celui qui paraît magnifique, ne vaut rien — et qu'un seul oubli d'une ligne de code suffit à fabriquer une performance imaginaire.

1. Le piège : prévoir le prix

Question 1. Chargez les cours et calculez les rendements logarithmiques, comme au TD précédent.

Question 2. Régressez le prix de demain sur le prix d'aujourd'hui. Relevez le R^2. Si vous en jugiez le modèle, que concluriez-vous ?

Question 3. Comparez maintenant votre modèle à une règle sans aucun paramètre : « *demain, le prix sera celui d'aujourd'hui* ». Calculez l'erreur quadratique moyenne des deux. Laquelle gagne ? Que valait donc le R^2 de la question 2 ?

2. Prévoir le rendement

Question 4. Construisez la **cible** — le rendement de demain — et une dizaine de **variables explicatives** connues la veille : rendements retardés de 1 à 5 jours, moyennes mobiles, volatilité récente, rendement du marché, volume, jour de la semaine. Chacune doit être décalée : vérifiez qu'aucune n'utilise une information du jour même.

Question 5. Découpez l'échantillon : les 80 % **premiers** en apprentissage, les 20 % **derniers** en test. Pourquoi ne découpe-t-on pas au hasard, comme on le ferait sur des données individuelles ?

Question 6. Estimez le modèle sur la partie apprentissage. Relevez son R^2. Puis prédisez la partie test et calculez le R^2 **hors échantillon**. Commentez l'écart.

Question 7. Un modèle de prévision ne se juge jamais seul. Comparez son erreur à celle de deux repères sans paramètre : prédire **zéro**, et prédire la **moyenne historique**. Le R^2 hors échantillon peut-il être négatif ? Qu'est-ce que cela voudrait dire ?

3. Prévoir seulement le sens

Question 8. Prévoir le montant est peut-être trop ambitieux. Combien de séances de la période de test sont en hausse ? C'est le **taux de base** : la performance d'un modèle qui dirait « en hausse » tous les jours.

Question 9. Votre modèle devine-t-il le sens mieux que ce taux de base ? L'écart est-il plus grand que l'incertitude d'échantillonnage sur n journées ?

4. Ce qui, lui, est prévisible

Question 10. Reprenez exactement le même code, mais changez la cible : prévoyez désormais la **valeur absolue** du rendement de demain — son amplitude, sans son sens. Relevez le R^2 hors échantillon.

Question 11. Le résultat n'est plus le même. Reliez-le au *regroupement de volatilité* : pourquoi l'amplitude est-elle prévisible alors que le sens ne l'est pas ? Et pourquoi cela n'a-t-il rien de contradictoire avec l'efficience des marchés ?

Question 12. Rédigez trois phrases : ce que vous avez réussi à prévoir, ce que vous n'avez pas réussi à prévoir, et pourquoi le second résultat est le plus intéressant des deux.

5. Pour ceux qui ont terminé

Question 13. [facultatif] **La fuite d'information.** Reprenez la volatilité glissante sur 5 jours et *retirez* le `.shift(1)` — l'oubli le plus courant. Le R^2 hors échantillon double. Expliquez d'où vient cette performance, et pourquoi elle est entièrement fausse.

Question 14. [facultatif] Essayez vingt variables explicatives tirées au hasard. Combien ressortent « significatives » à 5 % ? Que vous apprend ce nombre sur la lecture des p dans un modèle à nombreuses variables ?

Question 15. [facultatif] **Préparation de la séance 10.** Remplacez la régression linéaire par un `RandomForestRegressor`, sans rien changer d'autre — mêmes variables, même découpage, mêmes repères. Notez les deux R^2 hors échantillon. On en reparlera en cours.

Avant la séance suivante. Retenez la règle : **un modèle de prévision n'existe pas sans son repère et sans son découpage**. Un R^2 annoncé sans dire sur quelles données il a été calculé n'est pas un résultat, c'est une affirmation.