Dossier documentaire

Enquête Loyers 2025 — document à conserver pendant toute l'épreuve

1. Dictionnaire des variables

Variable	Type	Description et codes
IDENT	caractère	Identifiant du ménage.
NOLOG	entier	Numéro du logement occupé par ce ménage dans l'année (1, 2, ...).
REGION	caractère	Code région : 11 Île-de-France, 32 Hauts-de-France, 53 Bretagne, 76 Occitanie, 84 Auvergne-Rhône-Alpes.
TYPE	entier	1 appartement, 2 maison.
SURFACE	entier	Surface habitable en m^2. **999 : non-réponse.**
PIECES	entier	Nombre de pièces principales.
LOYER	décimal	Loyer mensuel hors charges, en euros. **0 : sans objet (ménage propriétaire). 9999 : non-réponse.**
ANCIENNETE	entier	Ancienneté dans le logement, en années. -1 **: sans objet (ménage propriétaire).**
REVENU	entier	Revenu annuel du ménage, en euros. **999 999 : non-réponse.**
POIDS	entier	Nombre de ménages de la population que représente cette ligne.

Champ. Ensemble des ménages de France métropolitaine. **Taille.** 2 560 lignes.

2. Extrait du fichier (12 lignes)

IDENT	NOLOG	REGION	TYPE	SURFACE	PIECES	LOYER	ANCIENNETE	REVENU	POIDS
00005	1	84	2	43	2	0.00	-1	76698	107
00006	1	11	1	74	4	9999.00	28	86202	396
00007	1	76	2	56	3	9999.00	17	79167	133
00007	2	76	2	44	3	382.76	17	79167	133
00037	1	11	2	999	3	1384.05	28	104088	391
00049	1	76	2	75	3	1053.62	6	53566	337
00104	1	84	1	75	3	1000.40	3	999999	207
00378	1	76	1	71	3	689.40	11	81406	68
00956	1	11	1	49	2	1066.53	24	48419	411
01201	1	11	1	46	2	1738.57	7	31262	248
01994	1	76	2	64	3	685.30	4	70446	209
02073	1	11	2	79	3	1843.19	26	85105	94

3. Trois régressions, sur le fichier complet nettoyé

Variable expliquée : $\log(\text{LOYER})$. $\texttt{lsurf} = \log(\text{SURFACE})$. `maison` vaut 1 si TYPE = 2. Écarts-types robustes entre parenthèses. $n = 1\,884$.

	(1)	(2)	(3)
lsurf	0,734***	0,910***	0,854***
	(0,025)	(0,034)	(0,021)
PIECES	—	0,016	0,020***
		(0,009)	(0,005)
maison	—	$-0{,}361^{***}$	0,047***
		(0,019)	(0,013)
Constante	3,881	3,327	3,769
Effets fixes de région	non	non	**oui**
R^2	0,316	0,434	0,819

*** $p < 0{,}01$. Coefficients des effets fixes de la colonne (3), référence = Île-de-France : Hauts-de-France $-0{,}858$; Bretagne $-0{,}731$; Occitanie $-0{,}707$; Auvergne-Rhône-Alpes $-0{,}612$.

4. Quelques chiffres du fichier complet

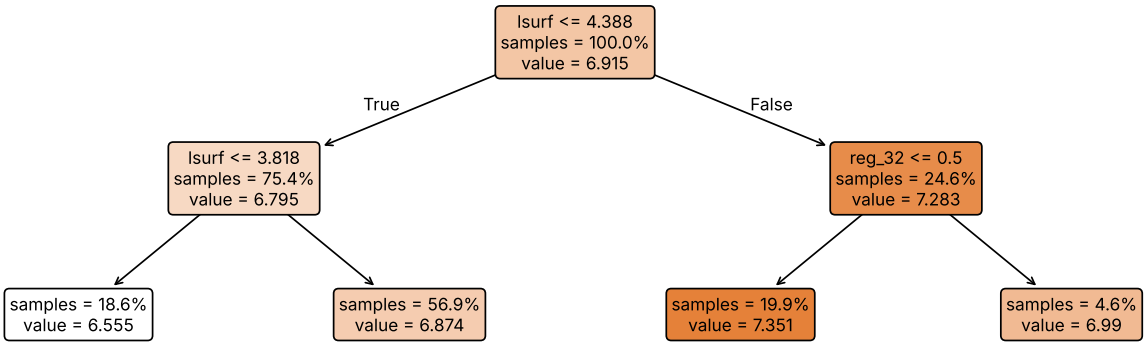
Lignes du fichier	2 560	Moyenne du loyer, brute	1 620,63
Identifiants `IDENT` distincts	2 400	. . .après `9999` $\rightarrow$ `NaN`	929,81
`df.isna().sum().sum()`	0	. . .locataires seulement	1 113,42
Lignes avec `LOYER` = 9 999	195	. . .surface renseignée	1 118,09
Lignes avec `LOYER` = 0	390	Moyenne pondérée	1 112,42
Lignes avec `SURFACE` = 999	103	Écart-type	551,1
Lignes avec `ANCIENNETE` = -1	390	Erreur-type	12,7

Loyers des 1 884 lignes retenues $q_1 = 733$ médiane $= 986$ $q_3 = 1\,360$ maximum $= 4\,293$

Par région part de maisons et loyer moyen au m^2 :
Île-de-France 24 % et 26,2 € A.-Rhône-Alpes 71 % et 14,4 € Occitanie 77 % et 13,1 €
Bretagne 81 % et 12,8 € Hauts-de-France 94 % et 11,3 € corrélation $= -0{,}99$

5. Un arbre de décision

Cible : $\log(\texttt{LOYER})$. Variables disponibles : `lsurf`, `PIECES`, `maison`, `ANCIENNETE` et les muettes de région (`reg_32` vaut 1 pour les Hauts-de-France). Profondeur maximale 2, apprentissage sur 1 507 lignes.



Rappel : $\log(45{,}5) = 3{,}818$ et $\log(80{,}5) = 4{,}388$. $e^{6{,}555} = 702$ $e^{6{,}874} = 967$ $e^{6{,}990} = 1\,086$ $e^{7{,}351} = 1\,557$.

6. Cinq modèles de prévision

Même cible, mêmes variables. Échantillon découpé au hasard : 1 507 lignes d'apprentissage, 377 de test.

Modèle	R^2 **en apprentissage**	R^2 **hors échantillon**
Régression linéaire	0,824	0,829
Arbre, profondeur 2	0,297	0,295
Arbre, profondeur 4	0,494	0,456
Arbre, profondeur 20	0,998	0,627
Forêt aléatoire, 300 arbres	0,869	0,797