TD 10 — Sujet d'annale

Analyse des données — L3 Économie — CY Cergy Paris Université

Durée indicative : 1 h 30. Sans machine. Le **dossier documentaire** est fourni à part : dictionnaire, extrait de 12 lignes, sorties de régression, arbre, tableaux de chiffres. Toutes les réponses s'y trouvent ou s'en déduisent.

Une réponse chiffrée sans justification ne vaut rien ; une justification juste avec une erreur de calcul vaut presque tout. Barème sur 20.

1. Lire le fichier

4 points

1. Que décrit une ligne de ce fichier ? Appuyez-vous sur l'extrait pour justifier.

2. Quelle combinaison de colonnes ne prend jamais deux fois la même valeur ? Pourquoi `IDENT` seul ne convient-il pas ?

3. Sur l'extrait de 12 lignes, combien de valeurs sont *réellement* manquantes ? Pourtant `df.isna().sum().sum()` renvoie **0** sur le fichier entier. Expliquez.

4. La ligne `00005` porte `LOYER = 0` et `ANCIENNETE = -1`. S'agit-il d'une erreur de saisie, d'une non-réponse, ou d'autre chose ? Que faut-il en faire si l'on étudie les loyers ?

5. Le ménage `00007` apparaît deux fois, avec le même `REVENU` et le même `POIDS`. Est-ce une anomalie ? Que se passerait-il si vous sommiez `REVENU` sur tout le fichier ?

6. Le dictionnaire déclare `REGION` de type caractère. Donnez deux conséquences concrètes de la charger en nombre.

7. La moyenne brute du `LOYER` vaut 1 620,63 € et la moyenne après nettoyage 1 118,09 €. Reconstituez les trois étapes qui mènent de l'une à l'autre, en donnant le chiffre intermédiaire et ce que chaque étape retire.

2. Diagnostiquer du code

3 points

8. Un étudiant écrit, pour mettre les non-réponses de loyer en valeur manquante :

```
df[df["LOYER"] == 9999]["LOYER"] = np.nan
```

puis `print(df["LOYER"].isna().sum())`. Qu'affiche le `print` ? Pourquoi ? Écrivez la forme correcte.

9. Il écrit ensuite `loc = df[df["LOYER"] > 0]` pour ne garder que les locataires, *après* avoir remplacé 9 999 par `NaN`. Combien de lignes cette instruction écarte-t-elle, et lesquelles ? Le résultat est-il celui qu'il voulait ?

10. Il fusionne le fichier avec une table de 5 régions par `merge(..., how="left")` et obtient 2 612 lignes au lieu de 2 560. Quelle est la cause ? Quel argument de `merge` aurait levé une erreur plutôt que de gonfler le tableau ?

11. Il filtre les ménages d'Île-de-France par `df[df["REGION"] == 11]` et obtient un tableau *vide*, sans aucun message d'erreur. Expliquez, puis corrigez.

12. Pour compter les logements par région, il écrit `df.groupby("REGION")["IDENT"].count()`. Ce décompte répond-il à la question « combien de *ménages* par région » ? Sinon, que faut-il écrire ?

3. Décrire, pondérer, repérer

4 points

13. Sur les 8 lignes de l'extrait qui ont un loyer et une surface renseignés, calculez la moyenne et la médiane du loyer. Laquelle des deux décrit le mieux ce petit groupe, et pourquoi ?

14. Toujours sur ces 8 lignes, la moyenne pondérée par `POIDS` vaut 1 081,39 € contre 1 057,47 € pour la moyenne simple. Qu'est-ce que l'écart signifie sur la composition de l'échantillon ?

15. Sur le fichier complet, l'écart-type des loyers vaut 551,1 et l'erreur-type 12,7. Expliquez la différence entre ces deux nombres, et dites lequel sert à construire un intervalle de confiance.

16. Appliquez la règle des 1,5 écarts interquartiles aux loyers du fichier nettoyé ($q_1 = 733$, $q_3 = 1\,360$). Donnez les deux seuils. Combien de loyers sont signalés vers le bas ? Expliquez ce résultat.

17. Faut-il retirer du fichier les loyers signalés vers le haut ? Justifiez en une phrase, et dites quel test vous feriez avant de décider.

18. Vous présentez l'évolution du loyer moyen sur cinq ans dans un rapport. On vous demande de « faire ressortir la hausse » en démarrant l'axe vertical à 900 € au lieu de 0. Que répondez-vous ?

4. Régresser

5 points

19. Dans la colonne (1), le coefficient de `lsurf` vaut 0,734. Énoncez en une phrase ce qu'il dit. Pourquoi n'est-il pas égal à 1 ?

20. De la colonne (1) à la colonne (2), ce coefficient *monte* à 0,910. Proposez une explication.

21. Dans la colonne (2), le coefficient de `PIECES` n'est pas significatif ; dans la colonne (3), il l'est à 1 %. Le coefficient a pourtant à peine bougé. Qu'est-ce qui a changé ?

22. Le coefficient de `maison` passe de $-0{,}361$ à $+0{,}047$ entre les colonnes (2) et (3). Traduisez les deux valeurs en pourcentage de loyer, puis expliquez le déplacement en vous appuyant sur les chiffres par région du dossier.

23. Lequel des deux coefficients de `maison` répond à la question « à surface et localisation données, une maison se loue-t-elle plus cher qu'un appartement ? » Justifiez.

24. Citez deux variables qui intéresseraient un économiste du logement et qu'il est **impossible** d'estimer dans la colonne (3). Pourquoi ?

25. Le R^2 passe de 0,434 à 0,819 entre les colonnes (2) et (3). Peut-on en conclure que la colonne (3) est « le bon modèle » ? Que mesure ce saut ?

5. Prévoir

3 points

26. Un logement de 95 m^2 situé dans les Hauts-de-France. Quel loyer l'arbre du dossier prédit-il ? Et s'il était en Île-de-France ? Détaillez le chemin suivi dans l'arbre.

27. L'arbre de profondeur 20 obtient 0,998 en apprentissage et 0,627 hors échantillon. Celui de profondeur 2 obtient 0,297 et 0,295. Nommez le défaut de chacun, et dites lequel des cinq modèles vous retiendriez.

28. Au TD 9, découper l'échantillon au hasard était interdit. Ici il est légitime. Qu'est-ce qui a changé ?

29. La forêt obtient 0,797 hors échantillon, la régression 0,829. Comment expliquez-vous qu'un modèle beaucoup plus souple fasse moins bien ?

30. Le tableau des importances d'une forêt place `lsurf` en tête. Peut-on en conclure qu'une surface plus grande fait monter le loyer de tant d'euros ? Justifiez.

6. Rédiger

1 point

31. En **cinq lignes au plus**, rédigez le paragraphe de résultats que vous placeriez sous la colonne (3) dans un rapport : ce que le modèle établit, en quelle unité, et ce qu'il ne permet pas de conclure.

Fin du sujet. Le dossier documentaire est à rendre avec la copie.